Algorytm genetyczny sterujący rakietą

Oliwia Wójcicka

19 października 2025

1 Opis algorytmu

Celem projektu było zaimplementowanie i przetestowanie algorytmu genetycznego.

Data: $q(x), P_0, \mu, p_m, p_c, t_{max}$
Result: $\hat{x}^*, \hat{o}^*$

```
begin
    t ← 0
    o ← ocena( q, P_0 )
    x̂*, ô* ← znajdź najlepszego( P_0, o )
    while t < t_max do
        R ← reprodukcja( P_t, o, μ )
        M ← krzyżowanie i mutacja( R, p_m, p_c )
        o ← ocena( q, M )
        x*_t, o*_t ← znajdź najlepszego( M, o )
        if o*_t < ô* then
            ô* ← o*_t
            x̂* ← x*_t
        end
        P_{t+1} ← M
        t ← t + 1
    end
end
```

Rysunek 1: Szkic działania algorytmu genetycznego (na podstawie materiałów z wykładu).

W niniejszym zadaniu algorytm genetyczny został zastosowany do optymalizacji sterowania rakietą, tak aby wylądowała jak najbliżej punktu docelowego (350m od startu). Każdy osobnik reprezentuje sekwencję sterowań silników w postaci ciągu binarnego. Funkcja celu oblicza odległość rakiety od celu po zakończeniu symulacji. Algorytm jest maksymalizujący – im mniejszy błąd (czyli rakieta bliżej celu), tym większa wartość funkcji celu.

Algorytm wykorzystuje następujące hiperparametry: μ – liczba osobników w populacji, p_m – prawdopodobieństwo mutacji, p_c – prawdopodobieństwo krzyżowania, $t_{\max}$ – liczba generacji oraz $n_{\text{genów}}$ – długość chromosomu. Dla każdej generacji wykonywana jest ocena osobników, selekcja rodziców metodą ruletkową, krzyżowanie i mutacja, a następnie aktualizacja populacji.

2 Opis testów i wyniki

W celu weryfikacji poprawności działania algorytmu przeprowadzono serię testów obejmującą rozwiązania trywialne, losowe oraz optymalizację przy pomocy algorytmu genetycznego.

Rozwiązania trywialne i losowe

Sterowanie	**Wynik funkcji celu**	**Błąd końcowy [m]**
Wszystkie wyłączone (0,0)	-122500.00	350.00
Wszystkie włączone (1,1)	-62455.54	249.91
Tylko poziome (1,0)	-122395.02	349.85
Tylko pionowe (0,1)	-122500.00	350.00
Losowe sterowanie	-118467.97	344.19

Tabela 1: Wyniki funkcji celu i błędu końcowego dla rozwiązań trywialnych i losowych.

Wyniki pokazują, że żadne z prostych sterowań nie pozwala na skuteczne zbliżenie się rakiety do punktu docelowego. Najlepszy spośród trywialnych przypadków daje wartość funkcji celu -62455.54, co wciąż oznacza odległość ok. 250 m od celu. Rozwiązanie losowe również wypada słabo. Dane te stanowią punkt odniesienia dla późniejszych testów z wykorzystaniem algorytmu genetycznego.

Górne ograniczenie

Teoretycznie najlepszy możliwy wynik funkcji celu wynosi 0, co odpowiada idealnemu trafieniu w punkt docelowy. W praktyce, ze względu na ograniczenia modelu, uzyskanie wartości bliskich zeru jest niemożliwe. Za bardzo dobry wynik przyjęto wartości funkcji celu powyżej -4, co odpowiada błędowi około 2 m.

Najlepszy zestaw hiperparametrów

Znaleziono zestaw hiperparametrów, który zapewnia stabilne i bardzo dobre wyniki dla 10 różnych losowych ziarien (seedów):

$$\mu = 80, \quad p_m = 0.001, \quad p_c = 0.9, \quad t_{\max} = 120.$$

Dla tego zestawu wszystkie dziesięć prób zakończyło się wynikiem funkcji celu wyższym niż -4, co oznacza, że rakieta w każdym przypadku dotarła bardzo blisko punktu docelowego. Wartości funkcji celu osiągnięte w poszczególnych przebiegach są zbliżone do zera, co świadczy o bardzo wysokiej skuteczności i stabilności algorytmu.

Metryka	**Wartość**
Liczba przypadków z wynikiem > -4	10/10
Średni wynik funkcji celu	-0.00005092
Odchylenie standardowe	0.00009022
Najlepszy wynik	-0.00000002
Najgorszy wynik	-0.00028133

Tabela 2: Podsumowanie wyników dla znalezionego zestawu hiperparametrów).

Uzyskane wartości są praktycznie zerowe, co oznacza niemal idealne trafienie w punkt docelowy. Algorytm genetyczny wykazuje dużą powtarzalność i odporność na losowość populacji początkowej.

Analiza wpływu parametru populacji μ

Aby zbadać wpływ liczby osobników w populacji (μ) na jakość rozwiązania, przeprowadzono serię eksperymentów dla różnych wartości μ, przy ustalonych wcześniej hiperparametrach.. Dla każdej wartości μ uruchomiono algorytm genetyczny i zarejestrowano wartość funkcji celu $q(x)$ oraz odpowiadający jej błąd końcowy.

Dodatkowo, aby zweryfikować stabilność działania algorytmu, eksperyment przeprowadzono dla dziesięciu różnych wartości losowego ziarna. Dla każdej liczby osobników μ algorytm uruchomiono dziesięciokrotnie, a uzyskane wyniki zostały uśrednione. Pozwoliło to ocenić, jak zmienia się średnia wartość funkcji celu i jej zmienność w zależności od rozmiaru populacji, przy tych samych pozostałych hiperparametrach.

μ	**Średni wynik** $q(x)$	**Odch. std.** $q(x)$	**Średni błąd [m]**	**Odch. std. błędu [m]**
10	-22000.461146	37849.846552	99.5568	109.9495
20	-3872.788078	9918.232763	30.7265	54.1172
30	-4459.327444	11138.028771	27.8968	60.6720
40	-180.690125	428.151547	5.7846	12.1338
50	-50.343522	150.939526	2.3070	6.7098
60	-0.001736	0.005055	0.0179	0.0376
80	-0.000051	0.000090	0.0046	0.0054
100	-53.675490	107.368227	3.2880	6.5471
120	-6.157275	18.463601	0.8067	2.3466
160	-0.004601	0.013664	0.0241	0.0634
200	-0.000088	0.000249	0.0044	0.0083
240	-0.000006	0.000007	0.0021	0.0014

Tabela 3: Średnie wyniki funkcji celu oraz błędu końcowego dla różnych wartości liczby osobników μ

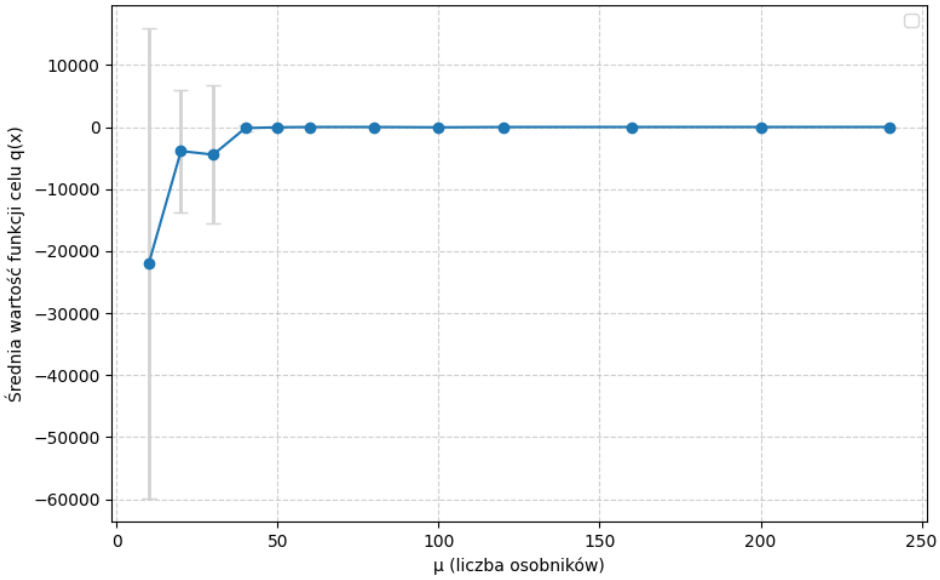

Rysunek 2: Wpływ liczby osobników μ na wynik funkcji celu i błąd

Wyniki pokazują, że dla małych populacji ($\mu < 60$) algorytm działa niestabilnie, a wartości funkcji celu znacznie odbiegają od zera. Towarzyszy im bardzo duży rozrzut wyników (wysokie odchylenie standardowe), co oznacza, że kolejne uruchomienia dają mocno zróżnicowane rezultaty. Świadczy to o zbyt małej różnorodności populacji i niewystarczającym przeszukiwaniu przestrzeni rozwiązań.

Wraz ze wzrostem liczby osobników jakość rozwiązań wyraźnie się poprawia – średnie wartości funkcji celu zbliżają się do zera, a odchylenie standardowe maleje, co oznacza większą powtarzalność i stabilność wyników. Dla $\mu \geq 80$ uzyskano bardzo dobre i spójne rezultaty, w których rakieta niemal idealnie trafia w cel. Dla $\mu = 100$ zaobserwowano chwilowe pogorszenie wyników. W większej populacji najlepsze osobniki mogły zdominować proces ewolucji zbyt wcześnie, co doprowadziło do utraty różnorodności genetycznej i przedwczesnego zatrzymania w lokalnym optimum. Po dalszym zwiększeniu liczby osobników efekt ten zanikł, a wyniki ponownie ustabilizowały się wokół wartości bliskich zeru. Zwiększanie liczby osobników powyżej 200 nie przynosi już dalszej poprawy jakości, a jedynie zwiększa koszt obliczeniowy.

3 Podsumowanie i wnioski

Przeprowadzone eksperymenty potwierdziły, że zastosowanie algorytmu genetycznego pozwala skutecznie rozwiązać zadanie sterowania rakietą. Rozwiązania trywialne i losowe dawały bardzo słabe wyniki funkcji celu, co oznaczało duże odchylenie od punktu docelowego. Po zastosowaniu algorytmu genetycznego wartości funkcji celu były bliskie zera, czyli rakieta niemal idealnie trafiała w wyznaczony cel.

Testy przeprowadzone dla dziesięciu różnych ziaren losowości potwierdziły, że działanie algorytmu dla znalezionych hiperparametrów jest stabilne i powtarzalne. We wszystkich przypadkach uzyskano wartości funkcji celu powyżej progu -4. Średni wynik był praktycznie równy zeru, co oznacza, że losowość populacji początkowej nie wpływa znacząco na jakość końcowego rozwiązania. Algorytm konsekwentnie dążył do optimum globalnego niezależnie od początkowego rozkładu genów.

Dodatkowo zbadano wpływ liczby osobników w populacji (μ) na jakość rozwiązania, przy ustalonych pozostałych hiperparametrach. Eksperyment przeprowadzono dla dziesięciu różnych wartości losowego ziarna, a uzyskane wyniki uśredniono, aby wyeliminować wpływ przypadkowości. Zaobserwowano wyraźny trend. Dla małych populacji wyniki były niestabilne i charakteryzowały się dużym rozrzutem. Wraz ze wzrostem liczby osobników wyniki stawały się bardziej stabilne i dokładne, a wartości funkcji celu zbliżały się do zera.

Podsumowując, algorytm genetyczny wykazał wysoką skuteczność, powtarzalność i odporność na losowość.

Bibliografia

[1] Materiały z wykładu nr 02

[2] Instrukcja do ćwiczenia laboratoryjnego