Algorytm genetyczny sterujący rakietą

Oliwia Wójcicka

18 października 2025

1 Opis algorytmu

Celem projektu było zaimplementowanie i przetestowanie algorytmu genetycznego.

Data: $q(x), P_0, \mu, p_m, p_c, t_{max}$
Result: $\hat{x}^*, \hat{o}^*$

```
begin
    t ← 0
    o ← ocena( q, P_0 )
    x̂*, ô* ← znajdź najlepszego( P_0, o )
    while t < t_max do
        R ← reprodukcja( P_t, o, μ )
        M ← krzyżowanie i mutacja( R, p_m, p_c )
        o ← ocena( q, M )
        x*_t, o*_t ← znajdź najlepszego( M, o )
        if o*_t < ô* then
            ô* ← o*_t
            x̂* ← x*_t
        end
        P_{t+1} ← M
        t ← t + 1
    end
end
```

Rysunek 1: Szkic działania algorytmu genetycznego (na podstawie materiałów z wykładu).

W niniejszym zadaniu algorytm genetyczny został zastosowany do optymalizacji sterowania rakietą, tak aby wylądowała jak najbliżej punktu docelowego (350m od startu). Każdy osobnik reprezentuje sekwencję sterowań silników w postaci ciągu binarnego. Funkcja celu oblicza odległość rakiety od celu po zakończeniu symulacji. Algorytm jest maksymalizujący – im mniejszy błąd (czyli rakieta bliżej celu), tym większa wartość funkcji celu.

Algorytm wykorzystuje następujące hiperparametry: μ – liczba osobników w populacji, p_m – prawdopodobieństwo mutacji, p_c – prawdopodobieństwo krzyżowania, $t_{\max}$ – liczba generacji oraz $n_{\text{genów}}$ – długość chromosomu. Dla każdej generacji wykonywana jest ocena osobników, selekcja rodziców metodą ruletkową, krzyżowanie i mutacja, a następnie aktualizacja populacji.

2 Opis testów i wyniki

W celu weryfikacji poprawności działania algorytmu przeprowadzono serię testów obejmującą rozwiązania trywialne, losowe oraz optymalizację przy pomocy algorytmu genetycznego.

Rozwiązania trywialne i losowe

Sterowanie	**Wynik funkcji celu**	**Błąd końcowy [m]**
Wszystkie wyłączone (0,0)	-122500.00	350.00
Wszystkie włączone (1,1)	-62455.54	249.91
Tylko poziome (1,0)	-122395.02	349.85
Tylko pionowe (0,1)	-122500.00	350.00
Losowe sterowanie	-121811.92	349.02

Tabela 1: Wyniki funkcji celu i błędu końcowego dla rozwiązań trywialnych i losowych.

Wyniki pokazują, że żadne z prostych sterowań nie pozwala na skuteczne zbliżenie się rakiety do punktu docelowego. Najlepszy spośród trywialnych przypadków daje wartość funkcji celu -62455.54, co wciąż oznacza odległość ok. 250 m od celu. Rozwiązanie losowe również wypada słabo. Dane te stanowią punkt odniesienia dla późniejszych testów z wykorzystaniem algorytmu genetycznego.

Górne ograniczenie

Teoretycznie najlepszy możliwy wynik funkcji celu wynosi 0, co odpowiada idealnemu trafieniu w punkt docelowy. W praktyce, ze względu na ograniczenia modelu, uzyskanie wartości bliskich zeru jest niemożliwe. Za bardzo dobry wynik przyjęto wartości funkcji celu powyżej -4, co odpowiada błędowi około 2 m.

Najlepszy zestaw hiperparametrów

Znaleziono zestaw hiperparametrów, który zapewnia stabilne i bardzo dobre wyniki dla 10 różnych losowych ziarien (seedów):

$$\mu = 80, \quad p_m = 0.001, \quad p_c = 0.9, \quad t_{\max} = 120.$$

Dla tego zestawu wszystkie dziesięć prób zakończyło się wynikiem funkcji celu wyższym niż -4, co oznacza, że rakieta w każdym przypadku dotarła bardzo blisko punktu docelowego. Wartości funkcji celu osiągnięte w poszczególnych przebiegach są zbliżone do zera, co świadczy o bardzo wysokiej skuteczności i stabilności algorytmu.

Metryka	Wartość
Liczba przypadków z wynikiem > -4	10/10
Średni wynik funkcji celu	-0.00005296
Odchylenie standardowe	0.00008422
Najlepszy wynik	-0.00000001
Najgorszy wynik	-0.00028133

Tabela 2: Podsumowanie wyników dla 10 losowych seedów (najlepszy zestaw hiperparametrów).

Uzyskane wartości są praktycznie zerowe, co oznacza niemal idealne trafienie w punkt docelowy. Algorytm genetyczny wykazuje dużą powtarzalność i odporność na losowość populacji początkowej.

Analiza wpływu parametru populacji μ

Aby zbadać wpływ liczby osobników w populacji (μ) na jakość rozwiązania, przeprowadzono serię eksperymentów dla różnych wartości μ, przy ustalonych wcześniej hiperparametrach.. Dla każdej wartości μ uruchomiono algorytm genetyczny i zarejestrowano wartość funkcji celu $q(x)$ oraz odpowiadający jej błąd końcowy.

Dodatkowo, aby zweryfikować stabilność działania algorytmu, eksperyment przeprowadzono dla sześciu różnych wartości losowego ziarna. Pozwoliło to sprawdzić, czy uzyskiwane wyniki są powtarzalne dla tych samych ustawień pozostałych hiperparametrów.

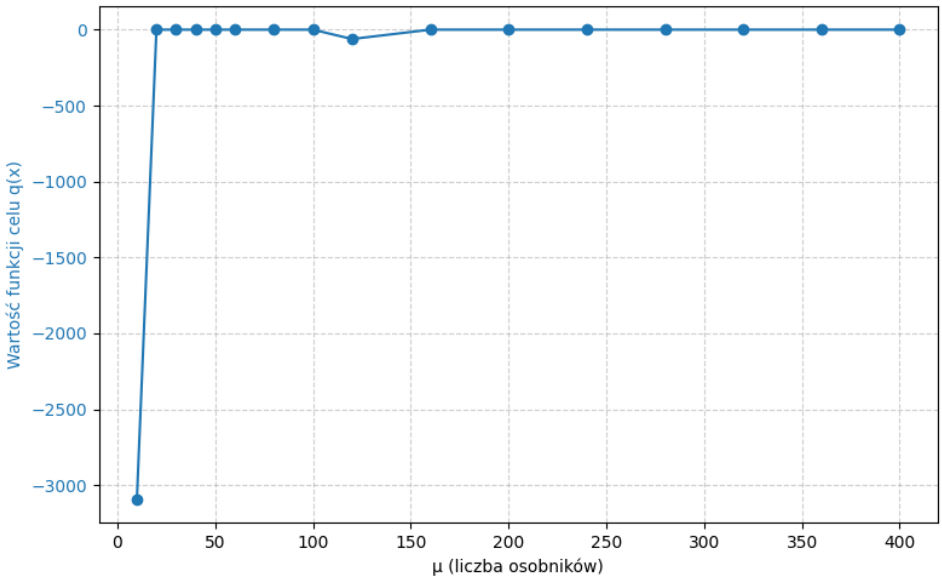

Rysunek 2: Wpływ liczby osobników μ na wynik funkcji celu i błąd, ziarno = 13.

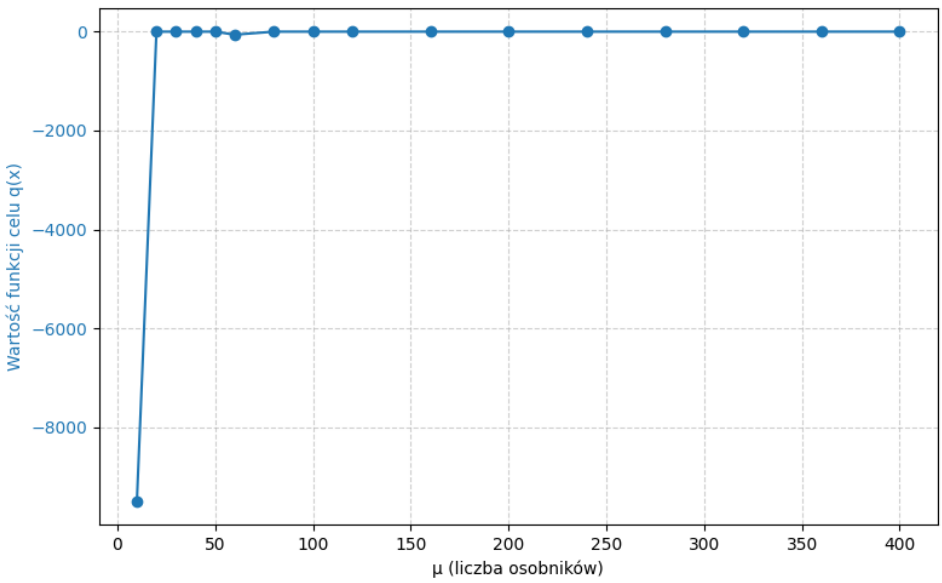

Rysunek 3: Wpływ liczby osobników μ na wynik funkcji celu i błąd, ziarno = 88.

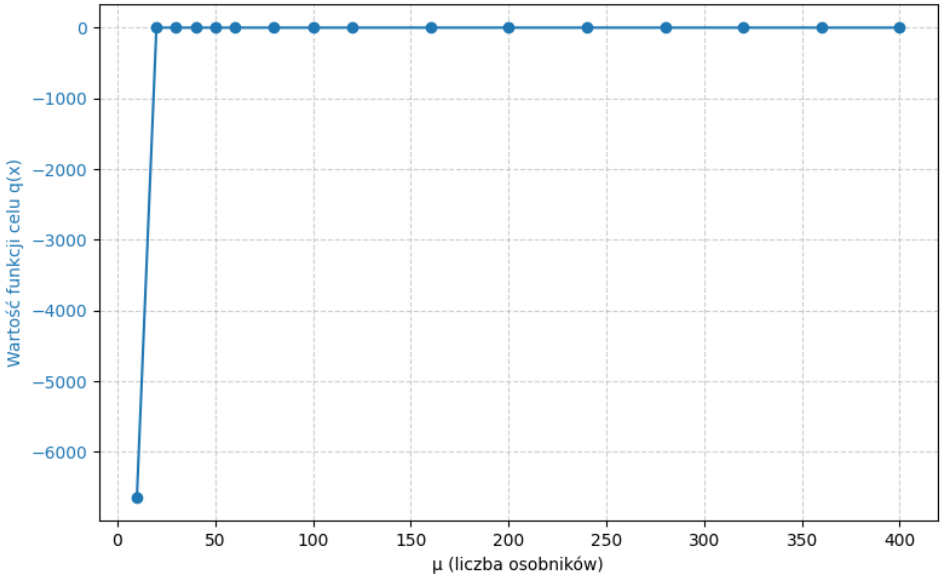

Rysunek 4: Wpływ liczby osobników μ na wynik funkcji celu i błąd, ziarno = 67.

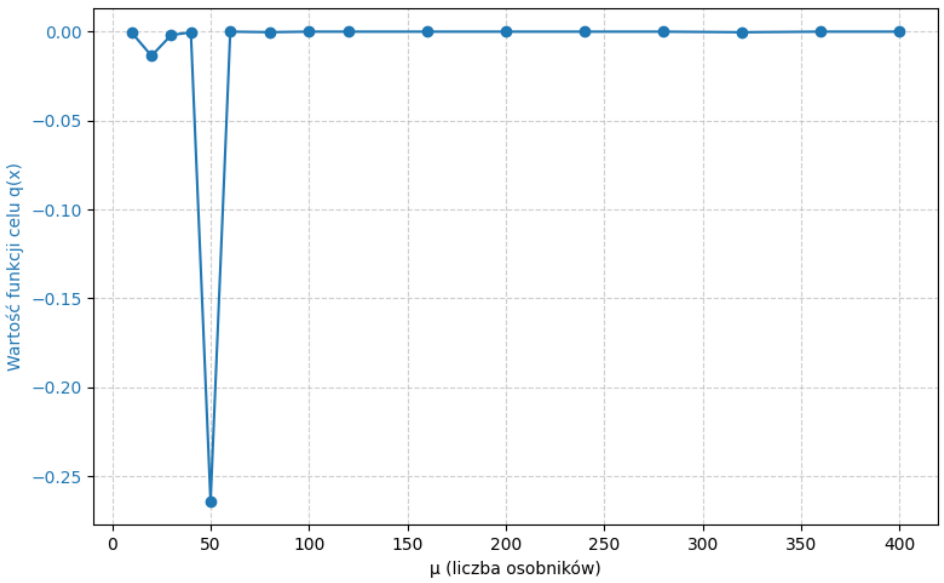

Rysunek 5: Wpływ liczby osobników μ na wynik funkcji celu i błąd, ziarno = 40.

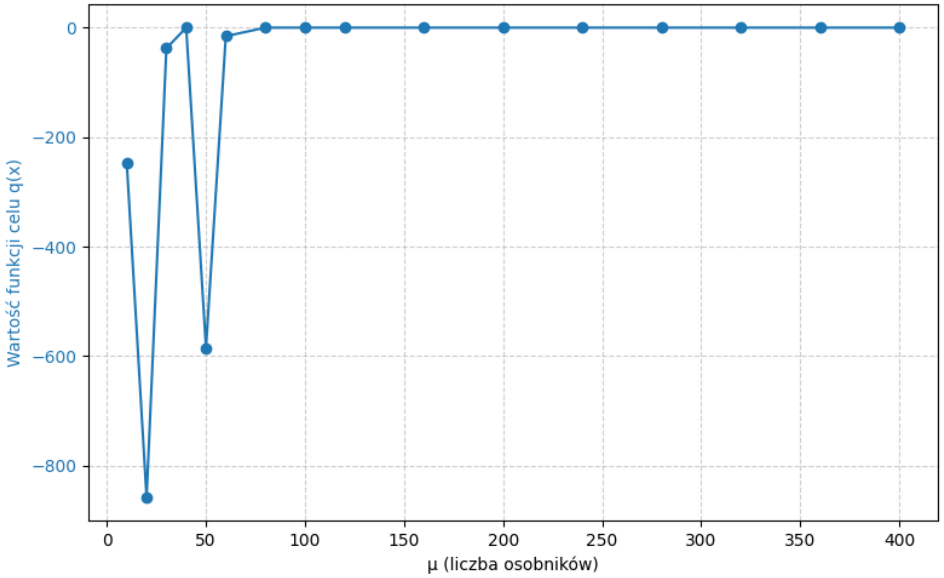

Rysunek 6: Wpływ liczby osobników μ na wynik funkcji celu i błąd, ziarno = 25.

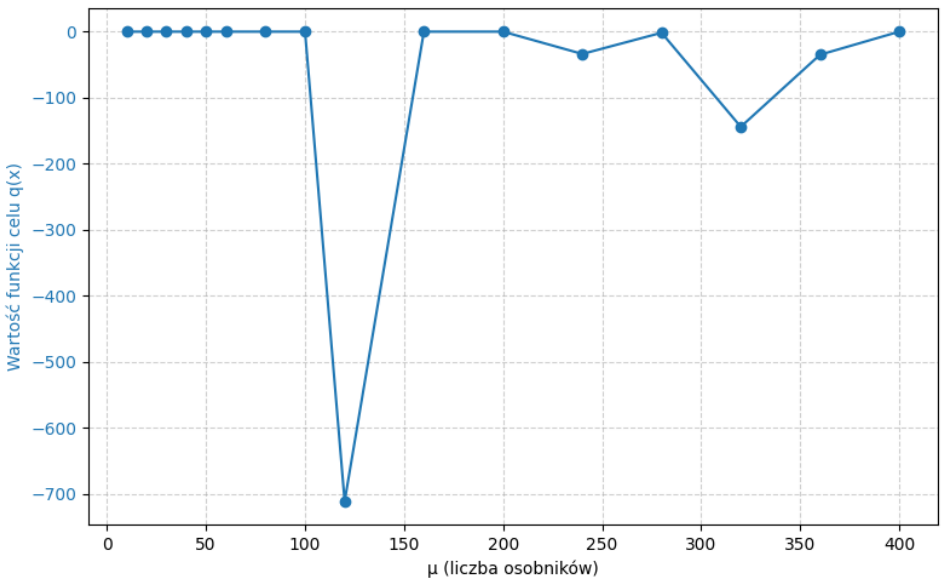

Rysunek 7: Wpływ liczby osobników μ na wynik funkcji celu i błąd, ziarno = 42.

Wyniki pokazują, że dla małych populacji ($\mu < 70$) wyniki są niestabilne, a wartości funkcji celu znacznie odbiegają od zera, co oznacza, że algorytm nie potrafi jeszcze dobrze przeszukać przestrzeni rozwiązań. Wraz ze wzrostem liczby osobników rozwiązania stają się coraz dokładniejsze i bardziej powtarzalne. Dla $\mu \geq 80$ uzyskano stabilne, bardzo dobre wyniki, w których rakieta trafia niemal idealnie w cel. Zwiększanie liczby osobników powyżej 200 nie przynosi już poprawy jakości rozwiązania, a jedynie wydłuża czas obliczeń.

W większości przypadków większe populacje prowadzą do lepszej optymalizacji i stabilniejszych wyników. Wyjątkiem jest jeden z eksperymentów, w którym przy $\mu \approx 120$ wystąpił gwałtowny spadek wartości funkcji celu, natomiast dla bardzo małych populacji wyniki były zaskakująco dobre.

3 Podsumowanie i wnioski

Przeprowadzone eksperymenty potwierdziły, że zastosowanie algorytmu genetycznego pozwala skutecznie rozwiązać zadanie sterowania rakietą. Rozwiązania trywialne i losowe dawały bardzo słabe wyniki funkcji celu, co oznaczało duże odchylenie od punktu docelowego. Po zastosowaniu algorytmu genetycznego wartości funkcji celu były bliskie zera, czyli rakieta niemal idealnie trafiała w wyznaczony cel.

Testy przeprowadzone dla dziesięciu różnych ziaren losowości potwierdziły, że działanie algorytmu dla znalezionych hiperparametrów jest stabilne i powtarzalne. We wszystkich przypadkach uzyskano wartości funkcji celu powyżej progu -4. Średni wynik był praktycznie równy zeru, co oznacza, że losowość populacji początkowej nie wpływa znacząco na jakość końcowego rozwiązania. Algorytm konsekwentnie dążył do optimum globalnego niezależnie od początkowego rozkładu genów.

Dodatkowo zbadano wpływ liczby osobników w populacji (μ) na jakość rozwiązania, przy ustalonych pozostałych hiperparametrach. Eksperyment przeprowadzono dla sześciu różnych random seedów, aby sprawdzić stabilność uzyskiwanych wyników. We wszystkich przypadkach zaobserwowano podobną tendencję — dla zbyt małych populacji ($\mu < 70$)

wyniki były niestabilne i gorsze, natomiast dla większych populacji ($\mu > 80$) funkcja celu przyjmowała wartości bliskie zera, a błąd końcowy był minimalny.

Tylko w jednym z sześciu eksperymentów pojawiały się pojedyncze przypadki silnych odchyleń wartości funkcji celu. Najprawdopodobniej było to spowodowane niekorzystnym rozkładem początkowej populacji, który ograniczył różnorodność genetyczną i doprowadził do lokalnego minimum.

Pomimo tego wyjątku, ogólny trend pozostał spójny. Większa liczba osobników znacząco poprawia stabilność i jakość rozwiązań, a sam algorytm genetyczny wykazuje wysoką skuteczność, powtarzalność i odporność na losowość początkowych warunków.

Bibliografia

[1] Materiały z wykładu nr 02

[2] Instrukcja do ćwiczenia laboratoryjnego