Algorytm Minimax z obcięciem alfa–beta w grze Szewc

Oliwia Wójcicka

4 listopada 2025

1 Opis algorytmu

Algorytm Minimax służy do podejmowania decyzji w grach strategicznych dla dwóch graczy, w których interesy graczy są przeciwne — zysk jednego jest stratą drugiego. W każdej turze gracze wykonują naprzemiennie ruchy, a każdy ruch zmienia stan gry. Algorytm przeszukuje możliwe sekwencje ruchów, próbując przewidzieć, jak przeciwnik może odpowiedzieć, i wybiera taki ruch, który maksymalizuje wynik bieżącego gracza przy założeniu, że przeciwnik gra optymalnie.

Gracz MAX wybiera ruch maksymalizujący wartość funkcji oceny, natomiast gracz MIN stara się tę wartość minimalizować. Przeszukiwanie odbywa się w formie drzewa stanów gry, gdzie liście oceniane są funkcją heurystyczną.

Aby ograniczyć liczbę rozważanych stanów, stosuje się technikę obcięcia alfa–beta. W każdym kroku utrzymywane są dwa progi:

- α – najlepszy (największy) wynik dotąd znaleziony dla gracza MAX,
- β – najlepszy (najmniejszy) wynik dotąd znaleziony dla gracza MIN.

Jeśli bieżąca wartość w węźle MAX przekroczy β, lub w węźle MIN spadnie poniżej α, dalsze rozwijanie tej gałęzi nie ma sensu, ponieważ przeciwnik nie dopuści do jej wyboru. Dzięki temu można pominąć dużą część drzewa przy zachowaniu tego samego wyniku co w klasycznym minimax.

Heurystyka

W implementacji gry Szewc zastosowano prostą heurystykę:

- podczas gry: różnica punktów (nasze – przeciwnika),
- po zakończeniu gry: $+\infty$ dla wygranej, $-\infty$ dla przegranej, 0 dla remisu.

2 Opis testów i wyniki

2.1 Konfiguracja

Testy przeprowadzono na planszy 4×4. Dla każdej pary głębokości przeszukiwania (d_A, d_B) z zakresu od 1 do 5 wykonano po 10 gier z różnymi ziarnami generatora losowego. W każdej rozgrywce stosowano losowy wybór ruchu, dla ruchów o tej samej jakości.

Wynikiem każdej gry jest różnica punktów $(A - B)$. Na ich podstawie obliczono:

- średnią wartość (mean),
- odchylenie standardowe (std),
- najlepszy wynik (best),
- najgorszy wynik (worst).

2.2 Przypadek trywialny dla głębokości 1

Gdy obaj gracze mają głębokość przeszukiwania $d_A = d_B = 1$, algorytm ocenia tylko najbliższy ruch bez przewidywania konsekwencji. Rozgrywki mają wtedy losowy charakter i często kończą się niewielką różnicą punktów.

d_A	d_B	mean	std
1	1	2.6	6.97

Tabela 1: Trywialny przykład testu dla głębokości przeszukiwania $d_A = d_B = 1$.

Średnia różnica punktów $(A-B)$ w serii 10 gier wyniosła około 2.6, a odchylenie standardowe 6.97, co oznacza znaczne wahania rezultatów pomiędzy poszczególnymi rozgrywkami.

Taki wynik jest spodziewany, ponieważ przy głębokości równej 1 algorytm analizuje wyłącznie bieżące ruchy, bez przewidywania dalszych konsekwencji swoich decyzji. W efekcie gracze nie są w stanie planować strategii ani kontrolować sytuacji na planszy — decyzje są w praktyce zbliżone do losowych.

Mimo że algorytm Minimax działa poprawnie, jego skuteczność przy tak płytkim drzewie decyzyjnym jest ograniczona.

2.3 Wpływ głebokości drzewa na wyniki

Przeprowadzono serię 10 gier dla każdej pary głębokości przeszukiwania (d_A, d_B) na planszy 4×4. Dla każdej pary (d_A, d_B) obliczono statystyki różnicy $(A - B)$. Wartość *mean* oznacza średnią różnicę punktów $(A - B)$, dodatnia wartość wskazuje na przewagę gracza A, a ujemna — gracza B.

d_A	d_B	mean	std	best	worst
1	1	2.60	6.97	12	-11
1	2	1.80	7.00	10	-16
1	3	2.50	7.61	12	-11
1	4	7.60	5.14	14	0
1	5	4.60	5.50	12	-4
2	1	2.80	4.66	8	-8
2	2	1.90	3.59	6	-4
2	3	4.80	5.65	12	-4
2	4	5.40	4.65	12	-2
2	5	9.60	4.15	14	2
3	1	0.60	4.39	8	-8
3	2	-4.40	6.87	8	-13
3	3	-0.50	5.10	7	-8
3	4	5.30	4.73	12	-6
3	5	6.60	4.48	12	0
4	1	-4.40	6.20	6	-13
4	2	-7.50	3.58	0	-13
4	3	-3.20	5.17	4	-14
4	4	-2.70	4.94	4	-10
4	5	4.60	4.10	10	-4
5	1	-9.10	2.88	-3	-12
5	2	-9.10	4.35	2	-15
5	3	-7.10	4.91	2	-16
5	4	-3.00	6.16	6	-12
5	5	4.10	4.74	10	-2

Tabela 2: Statystyki (mean, std, best, worst) dla par głębokości

Dodatkowo wyniki zostały przedstawione graficznie w postaci mapy cieplnej średnich różnic. Każda komórka obrazuje przewagę gracza A dla danej pary głębokości (d_A, d_B).

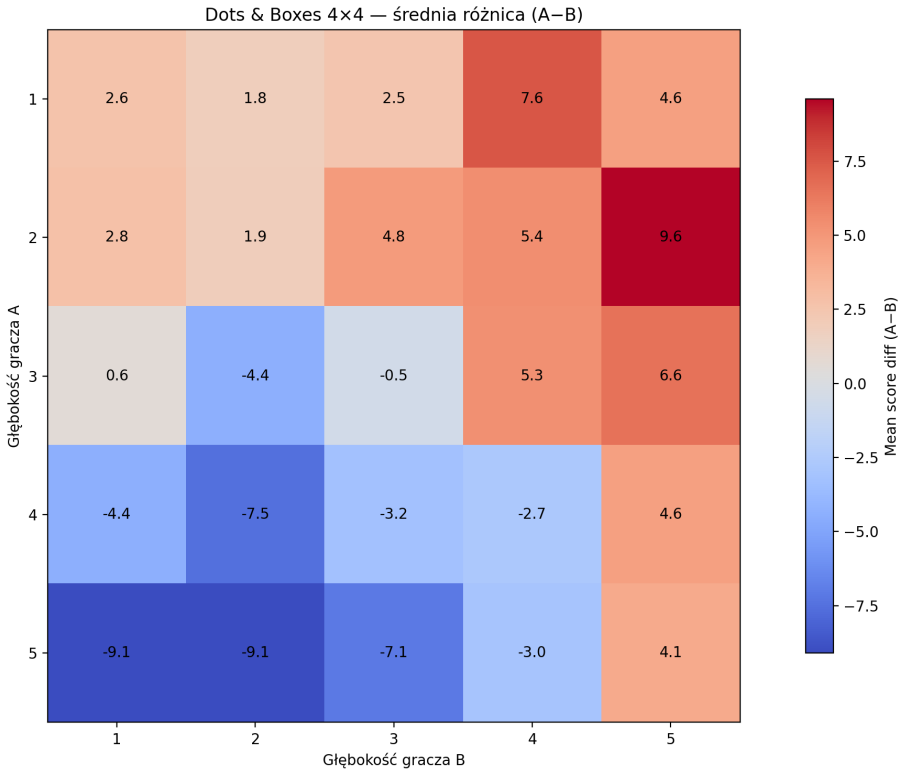

Rysunek 1: Mapa cieplna średniej różnicy punktów $(A - B)$ dla par głębokości

Na podstawie tabeli wyników i mapy cieplnej można sformułować następujące obserwacje:

1. **Zależność między głębokością a wynikiem nie jest monotoniczna.** Choć ogólnie większa głębokość przeszukiwania powinna dawać przewagę, w wynikach widać odstępstwa — np. dla $(A = 1, B = 5)$ gracz A mimo mniejszej głębokości uzyskuje dodatnią różnicę punktów. Może być to spowodowane regułą gry, w której zdobycie pola (czyli punktu) daje graczowi dodatkowy ruch. W efekcie gra staje się sekwencyjna: jeden błąd przeciwnika może oddać całą serię ruchów i doprowadzić do dużej straty punktowej. Nawet gracz o mniejszej głębokości może więc wykorzystać prosty lokalny zysk, jeśli przeciwnik zbyt długo „planował" ruchy kosztem bieżących korzyści.

2. **Przy małych głębokościach (1–2) obserwuje się dużą losowość wyników.** Wysokie odchylenie standardowe oznacza, że wynik zależy głównie od losowego przebiegu pierwszych kilku ruchów, które mogą otworzyć lub zamknąć możliwości zdobywania punktów.

3. **Dla dużych głębokości (4–5) algorytm planuje bardziej globalnie, ale heurystyka staje się kluczowa.** Funkcja heurystyczna, która opiera się głównie na różnicy punktów, nie zawsze właściwie ocenia pozycje w kontekście potencjalnych serii ruchów. Może to prowadzić do sytuacji, w której gracz analizujący zbyt głęboko poświęca lokalne punkty, licząc na długofalowy zysk, którego w praktyce nie realizuje z powodu struktury gry.

4. **Asymetria wyników wskazuje na znaczenie strategii sekwencyjnej.** Dodatkowy ruch po zdobyciu pola sprawia, że gracze muszą rozpoznawać sekwencje ruchów, które mogą oddać całą planszę jednemu z nich. Algorytm o mniejszej głębokości, który skupia się na natychmiastowych zyskach, może czasami podejmować decyzje bardziej korzystne w praktyce niż gracz analizujący zbyt szerokie drzewo.

3 Podsumowanie i wnioski

Na podstawie przeprowadzonych testów można zauważyć, że większa głębokość przeszukiwania nie zawsze prowadzi do lepszych wyników. Pojawiają się sytuacje, w których gracz analizujący płycej (np. d=1 lub d=2) osiąga wyraźnie lepsze rezultaty niż przeciwnik z głębokością d=4 lub d=5. Takie zjawisko jest ściśle związane ze specyfiką gry Szewc, która różni się od większości klasycznych gier dwuosobowych analizowanych algorytmem Minimax.

Dodatkowy ruch po zdobyciu pola: Największy wpływ na „dziwne" wyniki ma reguła, że zdobycie kwadratu daje graczowi dodatkowy ruch. W efekcie, pojedyncza decyzja może prowadzić do całej serii kolejnych punktów — nawet kilku lub kilkunastu w jednej turze. Algorytm Minimax, szczególnie przy ograniczonej głębokości, może błędnie ocenić sytuację, w której opłaca się poświęcić jeden punkt teraz, aby w kolejnych turach przejąć kontrolę nad całym łańcuchem. Zbyt płytki gracz kieruje się natychmiastową korzyścią i czasem przypadkiem aktywuje taką serię, co daje mu ogromną przewagę.

Efekt łańcuchów i pułapek końcówkowych. W końcowej fazie gry na planszy często pozostają tzw. łańcuchy — ciągi otwartych pól, które po wykonaniu jednego ruchu można „zebrać" jednym ciągiem. Optymalna strategia polega wtedy na oddaniu pojedynczego pola przeciwnikowi, aby zmusić go do rozpoczęcia łańcucha, a następnie przejęciu całej reszty. Gracz analizujący zbyt głęboko (ale z prostą heurystyką punktową) może takiej sytuacji nie przewidzieć, bo heurystyka nie rozpoznaje kontekstu łańcucha — widzi jedynie chwilowy zysk lub stratę.

Ograniczenia heurystyki. W tej implementacji heurystyka ocenia stan gry wyłącznie poprzez różnicę punktów (nasze - przeciwnika). W rezultacie, gracz o dużej głębokości może w teorii dokładnie analizować stan gry, ale ponieważ funkcja oceny jest uproszczona, jego decyzje są systematycznie błędne w sytuacjach strategicznych. Natomiast gracz o małej głębokości podejmuje decyzje prostsze i „lokalne" — często przypadkowo korzystniejsze.