Algorytm ID3

Oliwia Wójcicka

27 listopada 2025

1 Algorytm ID3

Algorytm ID3 służy do budowy drzew decyzyjnych na podstawie danych uczących. Jego celem jest iteracyjny wybór takiego atrybutu, który najlepiej porządkuje dane pod względem klasy, co mierzone jest za pomocą *przyrostu informacji (Information Gain)* . Proces budowy drzewa polega na rekurencyjnym dzieleniu zbioru uczącego na podzbiory, aż do spełnienia jednego z warunków stopu.

Indukcja drzew decyzyjnych — ID3

Algorithm 1: ID3

Input: Y: zbiór klas, D: zbiór atrybutów wejściowych, $U \neq \emptyset$: zbiór par uczących

if $\forall_{\{x_i, y_i\} \in U}\ y_i == y$ **then**
  return *Liść zawierający klasę y*
if $|D| == 0$ **then**
  return *Liść zawierający najczęstszą klasę w U*
$d = \arg\max_{d \in D} InfGain(d, U)$
$U_j = \{x_i, y_i\} \in U\ :\ x_i[d] = d_j$, gdzie d_j - j-ta wartość atrybutu d
return *Drzewo z korzeniem d oraz krawędziami* $d_j, j = 1, 2, \ldots$ *prowadzącymi do drzew: ID3(Y ,* $D - \{d\}$, U_1*), ID3(Y ,* $D - \{d\}$, U_2*),...*

Rysunek 1: Pseudokod algorytmu ID3 wykorzystany w implementacji

1.1 Entropia

Entropia jest miarą nieuporządkowania zbioru danych. Jeżeli zbiór składa się z elementów należących do kilku klas, to entropia jest wysoka; natomiast gdy wszystkie etykiety są takie same, entropia jest równa zero.

Dla zbioru U entropia zdefiniowana jest jako:

$$I(U) = -\sum_i f_i \ln(f_i),$$

gdzie f_i oznacza częstość występowania i-tej klasy w zbiorze.

1.2 Przyrost informacji

Aby wybrać najlepszy atrybut do podziału, algorytm ID3 oblicza tzw. *przyrost informacji* dla każdego dostępnego atrybutu. Przyrost informacji mierzy, o ile zmniejszy się entropia po podzieleniu zbioru na podzbiory według wartości danego atrybutu.

Entropia po podziale według atrybutu d definiowana jest jako:

$$Inf(d, U) = \sum_j \frac{|U_j|}{|U|} I(U_j),$$

gdzie U_j oznacza podzbiór przykładów, które mają tę samą wartość atrybutu d. Przyrost informacji obliczamy jako:

$$InfGain(d, U) = I(U) - Inf(d, U).$$

Im większy przyrost informacji, tym lepszy atrybut do rozgałęzienia drzewa.

2 Przygotowanie i wstępne przetwarzanie danych

W projekcie wykorzystano zbiór danych dotyczący stanu zdrowia pacjentów. Surowe dane zawierały wartości skrajnie nieprawdopodobne (np. ujemne ciśnienie, wzrost poniżej 60 cm), dlatego przed treningiem modelu konieczne było ich oczyszczenie i dyskretyzacja.

2.1 Konwersja wieku

W zbiorze pierwotnym wiek podany był w dniach, co utrudnia interpretację. Dlatego został przeliczony na lata.

2.2 Analiza wartości minimalnych i maksymalnych

Dla zmiennych ciągłych obliczono wartości minimalne i maksymalne. Analiza ujawniła występowanie licznych błędów pomiarowych, m.in.:

- wzrost: wartości od 55 do 250 cm,
- waga: od 10 do 200 kg,
- ciśnienie skurczowe `ap_hi`: od –150 do 16020,
- ciśnienie rozkurczowe `ap_lo`: od –70 do 11000.

Przykładowe obserwacje:

- wzrost 55 cm — fizycznie niemożliwy,
- ciśnienie 16020 mmHg — błąd pomiarowy,
- wartości ujemne ciśnienia — błędne rejestracje.

2.3 Czyszczenie danych

Na podstawie przedziałów akceptowalnych wartości medycznych zastosowano filtrację:

```
height   [110, 230]
weight   [35, 200]
ap_hi    [50, 180]
ap_lo    [40, 120]
```

Celem filtracji było usunięcie oczywistych błędów pomiarowych przy jednoczesnym zachowaniu pełnej informacji klinicznej.

Usunięto około 2,3% danych — wyłącznie obserwacje niepoprawne, niefizyczne lub zapisane błędnie. Oczyszczony zbiór stanowi solidną podstawę do dalszej analizy i budowy modelu drzewa decyzyjnego.

2.4 Analiza zmiennych ciągłych

Dla zmiennych: `height`, `weight`, `ap_hi`, `ap_lo` oraz `age_years` wykonano histogramy, aby określić odpowiednie przedziały do dyskretyzacji.

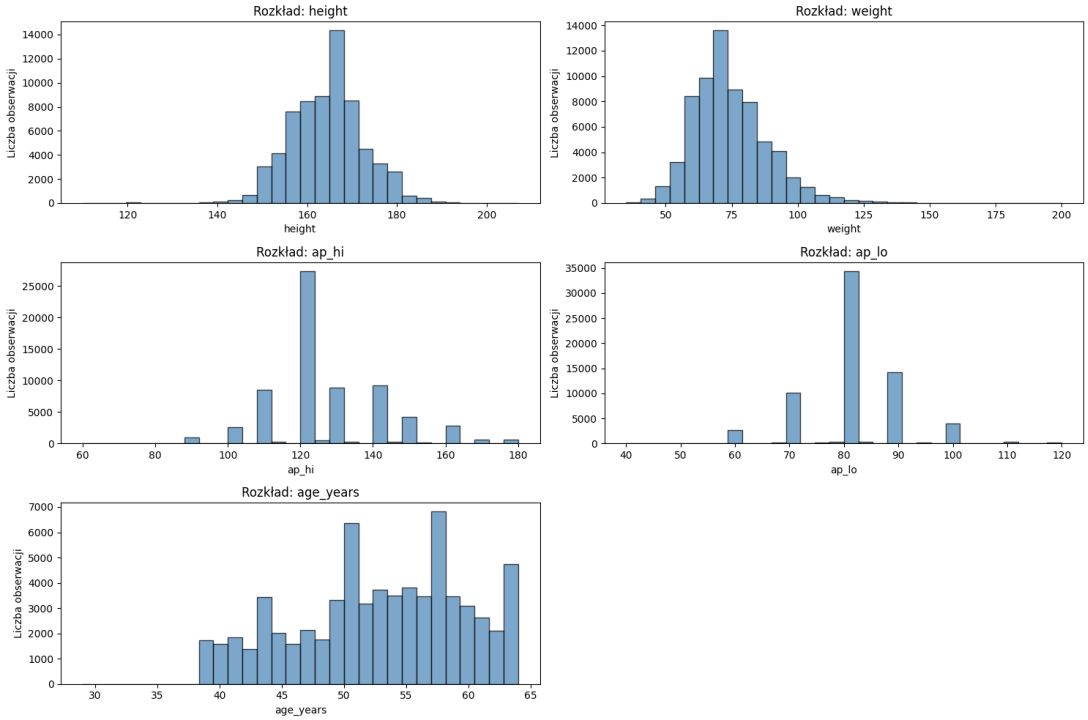

Rysunek 2: Histogramy zmiennych ciągłych przed dyskretyzacją

2.5 Dyskretyzacja zmiennych ciągłych

Zmienne ciągłe zostały podzielone na przedziały, a następnie zamienione na liczby. Umożliwia to wykorzystanie ich przez algorytm ID3.

2.6 Finalna postać danych wejściowych

Po zakończeniu procesu czyszczenia i dyskretyzacji końcowa ramka danych wykorzystana do budowy drzewa decyzyjnego miała postać:

age_group	height_group	weight_group	ap_hi_group	ap_lo_group	gender	cholesterol	gluc	smoke	alco	active	cardio
3	1	2	2	1	1	2	2	0	0	1	0
0	2	3	1	1	1	1	1	0	0	1	1
2	2	2	2	1	1	1	1	0	0	1	0
0	2	4	1	1	2	1	1	1	1	1	0
3	1	2	2	1	1	1	1	0	0	1	0

Tabela 1: Przykładowe rekordy po procesie czyszczenia

3 Eksperymenty i ocena jakości modelu

W celu oceny jakości implementowanego algorytmu ID3 przeprowadzono serię eksperymentów z wykorzystaniem podziału zbioru danych na trzy części:

- **70%** – zbiór treningowy,
- **15%** – zbiór walidacyjny,
- **15%** – zbiór testowy.

Aby uzyskać stabilniejszą ocenę jakości, cały proces powtórzono dla 10 różnych wartości ziaren losowych. Dla każdej iteracji trenowano drzewa o maksymalnej głębokości od 1 do 20, a następnie obliczano dokładność (accuracy) na zbiorze treningowym oraz walidacyjnym.

max_depth	**train_mean**	**train_std**	**val_mean**	**val_std**
1	0.710232	0.000581	0.709406	0.001804
2	0.717810	0.000663	0.716310	0.003350
3	0.727508	0.000998	0.724653	0.003454
4	0.732850	0.001247	0.725618	0.003349
5	0.740672	0.001157	0.721353	0.003630
6	0.752171	0.001034	0.714163	0.004189
7	0.765417	0.000756	0.707387	0.005519
8	0.776918	0.000668	0.702502	0.005584
9	0.785268	0.000582	0.699626	0.004223
10	0.789926	0.000522	0.697242	0.004625
11	0.791731	0.000554	0.696238	0.004721
12	0.791731	0.000554	0.696238	0.004721
13	0.791731	0.000554	0.696238	0.004721
14	0.791731	0.000554	0.696238	0.004721
15	0.791731	0.000554	0.696238	0.004721
16	0.791731	0.000554	0.696238	0.004721
17	0.791731	0.000554	0.696238	0.004721
18	0.791731	0.000554	0.696238	0.004721
19	0.791731	0.000554	0.696238	0.004721
20	0.791731	0.000554	0.696238	0.004721

Tabela 2: Średnie wyniki accuracy na zbiorach treningowych i walidacyjnych w zależności od głębokości drzewa (10 losowych seedów).

3.1 Najlepsza głębokość na podstawie zbioru treningowego

Najwyższą średnią dokładność na zbiorze treningowym osiągały drzewa o dużych głębokościach:

$$\boxed{\textbf{Najlepsza głębokość (TRAIN)} = 11\text{–}20}$$

przy czym accuracy osiągało:

$$\text{train_mean} = 0.7917.$$

Warto zauważyć, że wartości train_mean pozostają identyczne dla wszystkich głębokości od 11 do 20. Wynika to z faktu, że ramka danych użyta do trenowania modelu zawiera dokładnie 11 atrybutów wejściowych. Drzewo decyzyjne wykorzystuje każdy atrybut maksymalnie raz na ścieżkę, dlatego po osiągnięciu głębokości równej liczbie cech nie jest możliwe dalsze dzielenie danych.

Oznacza to, że dla głębokości większych niż 11 struktura drzewa pozostaje niezmieniona, a więc również dokładność treningowa nie może już ulec poprawie. Stabilizacja wyników dla max_depth ≥ 11 jest więc naturalną konsekwencją ograniczenia liczby dostępnych cech.

Tak wysoka wartość dla dużych głębokościach sugeruje przeuczenie (overfitting), dlatego do wyboru modelu stosowano zbiór walidacyjny.

3.2 Najlepsza głębokość na podstawie walidacji

Najwyższa średnia dokładność na zbiorze walidacyjnym została osiągnięta dla:

$$\boxed{\textbf{Najlepsza głębokość (VAL)} = 4}$$

z wynikiem:

$$\text{val_mean} = 0.7256.$$

Głębokość 4 stanowi najlepszy kompromis między dopasowaniem a prostotą modelu.

3.3 Wynik końcowy na zbiorze testowym

Po wybraniu optymalnej głębokości (max_depth = 4) model został ponownie przetrenowany i oceniony na zbiorze testowym. Wynik końcowy:

$$\boxed{\text{TEST accuracy} = 0.7274 \pm 0.0034}$$

Uzyskany rezultat potwierdza stabilność modelu oraz poprawność wyboru głębokości drzewa.

Na podstawie średniego wyniku walidacyjnego najlepszą okazała się głębokość:

$$\boxed{\textbf{max_depth} = 4}$$

gdyż zapewniała ona najwyższą średnią dokładność walidacyjną (val_mean = 0.7256) oraz jednocześnie unikała przeuczenia (train_mean = 0.7328).

4 Porównanie z gotową implementacją `DecisionTreeClassifier`

Aby ocenić jakość działania własnej implementacji algorytmu ID3, przeprowadzono dodatkowy eksperyment porównawczy z wykorzystaniem klasyfikatora `DecisionTreeClassifier` z biblioteki `scikit-learn`. Oba modele trenowano na tych samych danych (po czyszczeniu i dyskretyzacji), stosując identyczny podział 70/15/15 oraz testując na 10 różnych wartościach ziaren losowych.

- **Najlepsza głębokość (TRAIN):** $d = 20$, accuracy $= 0.7877$
- **Najlepsza głębokość (VAL):** $d = 5$, accuracy $= 0.7280$
- **Wynik na zbiorze TEST (dla $d = 5$):** accuracy $= 0.7296 \pm 0.0031$

Wniosek

Przeprowadzone porównanie potwierdza, że autorska implementacja ID3 działa poprawnie i uzyskuje wyniki praktycznie nieodróżnialne od profesjonalnej implementacji z biblioteki scikit-learn. Oznacza to, że obliczanie entropii, zdobycz informacyjna oraz logika budowy drzewa zostały wykonane prawidłowo.

5 Podsumowanie

- Na danych treningowych najwyższe accuracy uzyskiwały drzewa o największych głębokościach. Jest to zgodne z teorią: głębokie drzewa bardzo dobrze dopasowują się do danych uczących, co prowadzi do wysokiej skuteczności na treningu, lecz zwiększa ryzyko przeuczenia.
- Najlepszą głębokość drzewa wybrano na podstawie wyników walidacyjnych. Maksymalne średnie accuracy na zbiorze walidacyjnym osiągnięto dla głębokości $d = 4$, co świadczy o tym, że zbyt duża złożoność modelu nie poprawia uogólnienia.
- Ocena modelu o głębokości $d = 4$ na zbiorze testowym dała wynik **accuracy = 0.7274**, który jest zbliżony do wyników walidacyjnych. Oznacza to, że wybrany model nie jest przeuczony i dobrze generalizuje na nowych danych.
- Ostateczna jakość predykcyjna modelu jest bardzo podobna do wyników uzyskanych z wykorzystaniem klasyfikatora `DecisionTreeClassifier` ze scikit-learn, co potwierdza poprawność implementacji zarówno funkcji entropii, przyrostu informacji, jak i mechanizmu budowy drzewa decyzyjnego.