Analiza działania algorytmu Gradient Descent na funkcji Ackleya

Oliwia Wójcicka

10.12.2025

1 Algorytm Gradient Descent

Algorytm Gradient Descent jest podstawową iteracyjną metodą służącą do znajdowania minimum funkcji różniczkowalnych. Algorytm aktualizuje punkt w kierunku przeciwnym do gradientu:

$$x_{k+1} = x_k - \alpha \nabla f(x_k),$$

gdzie $\alpha > 0$ jest krokiem nauki. Metoda ta dobrze sprawdza się dla funkcji gładkich i wypukłych, natomiast w przypadku funkcji wielomodalnych (posiadających wiele minimów lokalnych) może łatwo utknąć w lokalnych minimach, oscylować lub nie zbiegać. Warunek stopu zwykle opiera się na normie gradientu:

$$\|\nabla f(x_k)\| \leq \varepsilon.$$

co oznacza osiągnięcie punktu stacjonarnego.

2 Funkcja Ackleya

Zgodnie z treścią zadania analizujemy działanie algorytmu Gradient Descent na funkcji Ackleya w wersji jednowymiarowej i dwuwymiarowej, opisanych odpowiednio wzorami:

$$f(x) = -20 \exp\left(-0.2\sqrt{x^2}\right) - \exp(\cos(2\pi x)) + 20 + e.$$

$$f(x,y) = -20 \exp\left(-0.2\sqrt{\frac{x^2+y^2}{2}}\right) - \exp\left(\frac{\cos(2\pi x) + \cos(2\pi y)}{2}\right) + 20 + e.$$

W obu przypadkach funkcja posiada jedno globalne minimum zlokalizowane w punkcie:

$$(x^*, y^*) = (0,0), \qquad f(0,0) = 0.$$

natomiast liczne oscylacje powodują, że otoczenie funkcji jest pełne minimów lokalnych o różnych głębokościach. To sprawia, że Ackley stanowi wymagający test dla algorytmów optymalizacji lokalnej - takich jak Gradient Descent - i pozwala obserwować typowe problemy związane z ich stosowaniem w kontekście funkcji wielomodalnych.

3 Eksperyment 1: Minima funkcji Ackleya

W pierwszym etapie przeprowadzono test działania algorytmu Gradient Descent dla ustalonych parametrów

$$x_0 = [2.0], \qquad \alpha = 0.01, \qquad \varepsilon = 10^{-6}$$

w przypadku funkcji jednowymiarowej oraz

$$x_0 = [1.0,\ 1.0], \qquad \alpha = 0.01, \qquad \varepsilon = 10^{-6}$$

dla wersji dwuwymiarowej.

Otrzymane minima były następujące:

$$x_{\min}^{(1D)} = 1.97445199, \qquad f\left(x_{\min}^{(1D)}\right) = 6.55964538,$$

$$(x_{\min}^{(2D)}, y_{\min}^{(2D)}) = (0.96847767,\ 0.96847767), \qquad f\left(x_{\min}^{(2D)}, y_{\min}^{(2D)}\right) = 3.574451877.$$

Żaden z otrzymanych wyników nie jest nawet bliski wartości globalnego minimum funkcji Ackleya, które wynosi

$$(x^\star, y^\star) = (0, 0), \qquad f(0, 0) = 0.$$

Co więcej, wartości funkcji w znalezionych punktach ($f > 3$) jednoznacznie potwierdzają, że nie są to minima globalne. Już na tym etapie zauważyłam również wyraźną zależność wyniku od wyboru punktu startowego, co zostanie dokładniej przeanalizowane w kolejnych eksperymentach.

4 Eksperyment 2: Wpływ rozmiaru kroku α na działanie algorytmu

Kolejnym etapem było zbadanie, w jaki sposób wybór parametru kroku α wpływa na działanie algorytmu. W tym celu uruchomiono algorytm dla wielu różnych wartości α, przy stałych parametrach:

$$x_0 = 2.0 \quad \text{(1D)}, \qquad (x_0, y_0) = (2.0, 2.0) \quad \text{(2D)}, \qquad \varepsilon = 10^{-6}.$$

Dla każdej wartości kroku zarejestrowano przebieg funkcji $f(x_k)$ w kolejnych iteracjach oraz zachowanie algorytmu pod względem zbieżności lub niestabilności.

5 Eksperyment 3: Wpływ rozmiaru kroku α na działanie algorytmu

W kolejnym etapie przeprowadzono analizę wpływu parametru kroku α na zachowanie algorytmu gradientu prostego. W tym celu uruchomiono algorytm dla wielu różnych wartości α, zarówno dla funkcji Ackleya w wymiarze 1, jak i 2, przy stałych parametrach:

$$x_0 = 2.0 \quad (1\text{D}), \qquad (x_0, y_0) = (2.0, 2.0) \quad (2\text{D}), \qquad \varepsilon = 10^{-6}.$$

Dla każdej wartości kroku zarejestrowano przebieg funkcji $f(x_k)$ w kolejnych iteracjach oraz zachowanie algorytmu pod względem zbieżności lub niestabilności.

5.1 Wykresy

Poniższe wykresy przedstawiają zachowanie algorytmu dla różnych wartości parametru α. Każdy wykres odpowiada innej wartości kroku, co umożliwia porównanie dynamiki zbieżności.

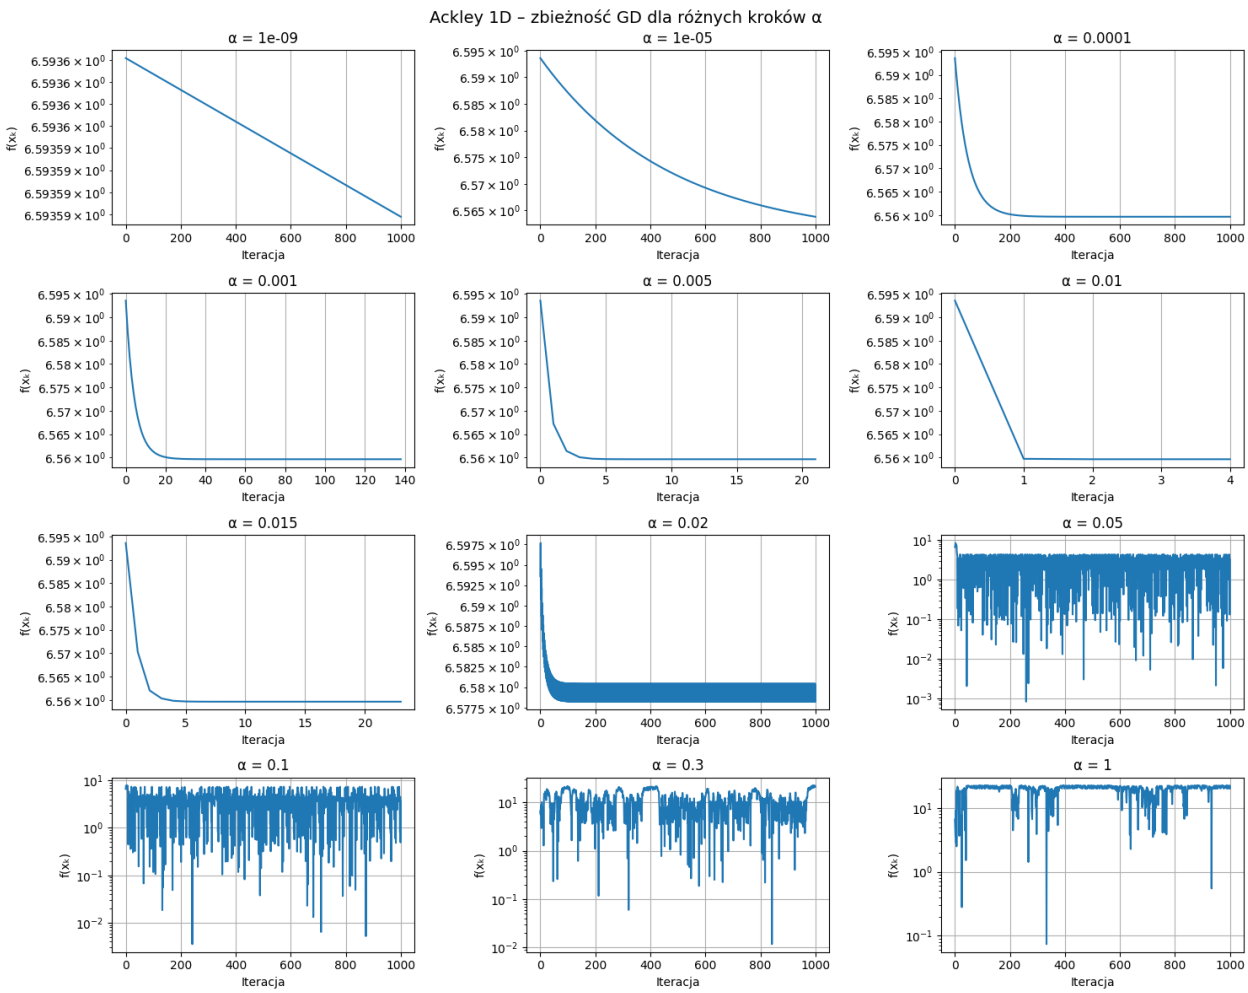

Rysunek 1: zbieżność Gradient Descent na funkcji Ackleya 1D kroku

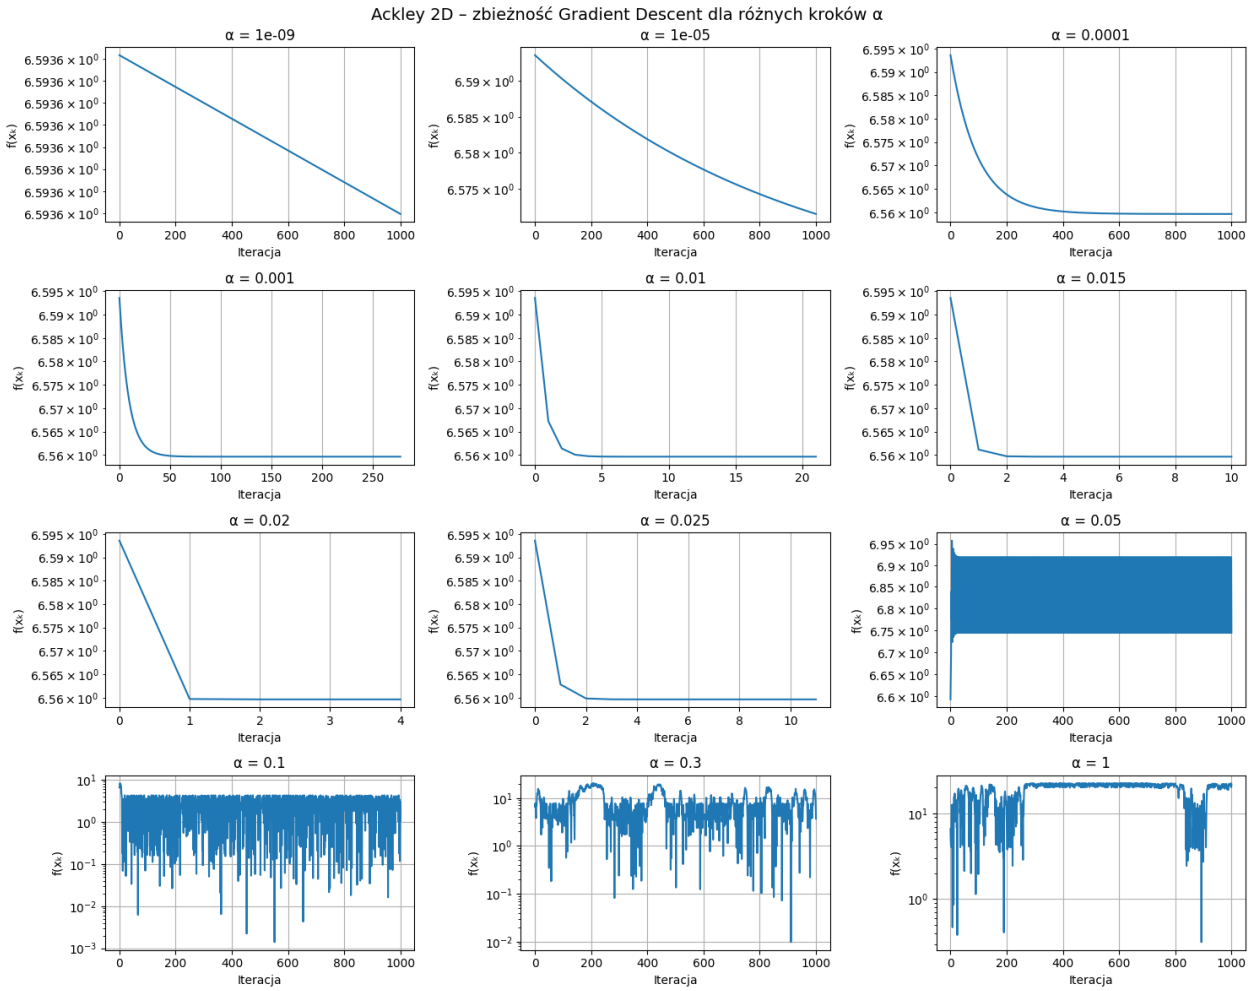

Rysunek 2: zbieżność Gradient Descent na funkcji Ackleya 2D

Wnioski na podstawie wykresów

Analiza wykresów dla różnych wartości kroku α pozwala wyciągnąć kilka obserwacji dotyczących zachowania algorytmu Gradient Descent:

- **Bardzo małe wartości** α powodują bardzo wolne działanie algorytmu. Zmiany wartości funkcji w kolejnych iteracjach są minimalne, a algorytm wykonuje dużą liczbę kroków, praktycznie stojąc w miejscu.
- **Średnie wartości kroku** (w okolicach α około 10^{-3}–10^{-2}) prowadzą do najbardziej stabilnej i najszybszej zbieżności. W tych przypadkach wykresy pokazują szybkie obniżanie wartości funkcji, a liczba iteracji jest najmniejsza.
- **Duże wartości** α powodują utratę stabilności metody. Wartości $f(x_k)$ zaczynają oscylować, niekiedy bardzo gwałtownie, a algorytm nie jest w stanie ustabilizować się w żadnym punkcie.

Podsumowując, wybór parametru kroku ma kluczowe znaczenie dla stabilności i szybkości algorytmu. Dobrze dobrane średnie wartości α pozwalają osiągnąć szybką zbieżność, natomiast zbyt małe lub zbyt duże kroki prowadzą odpowiednio do bardzo wolnego działania lub do niestabilności.

5.2 Wyniki numeryczne

α	Iteracje	$x_{\min}$	$f(x_{\min})$
10^{-9}	1001	1.999997	6.593592
10^{-5}	1001	1.983483	6.563825
10^{-4}	1001	1.974453	6.559645
10^{-3}	139	1.974452	6.559645
$5 \cdot 10^{-3}$	22	1.974452	6.559645
10^{-2}	5	1.974452	6.559645
$1.5 \cdot 10^{-2}$	24	1.974452	6.559645
$2 \cdot 10^{-2}$	1001	1.993397	6.578220
$5 \cdot 10^{-2}$	1001	-0.304790	3.187469
10^{-1}	1001	-0.966769	3.574595
$3 \cdot 10^{-1}$	1001	-22.824044	20.943882
1	1001	97.053690	20.148973

Tabela 1: Wyniki minimalizacji funkcji Ackleya 1D

α	Iteracje	$(x_{\min}, y_{\min})$	$f(x_{\min}, y_{\min})$
10^{-9}	1001	(1.999998, 1.999998)	6.593595
10^{-5}	1001	(1.989606, 1.989606)	6.571489
10^{-4}	1001	(1.974604, 1.974604)	6.559647
10^{-3}	278	(1.974452, 1.974452)	6.559645
10^{-2}	22	(1.974452, 1.974452)	6.559645
$1.5 \cdot 10^{-2}$	11	(1.974452, 1.974452)	6.559645
$2 \cdot 10^{-2}$	5	(1.974452, 1.974452)	6.559645
$2.5 \cdot 10^{-2}$	12	(1.974452, 1.974452)	6.559645
$5 \cdot 10^{-2}$	1001	(2.033833, 2.033833)	6.744515
10^{-1}	1001	(-0.116062, -0.116062)	1.069301
$3 \cdot 10^{-1}$	1001	(0.381496, 0.381496)	3.708173
1	1001	(-33.749212, -33.749212)	21.699794

Tabela 2: Wyniki minimalizacji funkcji Ackleya 2D

Wnioski na podstawie wyników z tabel

Z tabel wynika, że średnie wartości kroku α (około 10^{-3}–10^{-2}) powodują najszybszą zbieżność algorytmu - liczba iteracji jest wtedy znacznie mniejsza niż dla bardzo małych lub dużych kroków.

Jednak mimo różnic w szybkości zbieżności wszystkie znalezione punkty $x_{\min}$ oraz $f(x_{\min})$ (zarówno w 1D, jak i w 2D) są wyraźnie oddalone od faktycznego minimum globalnego funkcji Ackleya. Oznacza to, że Gradient Descent regularnie zatrzymuje się w minimach lokalnych, co wynika z silnie multimodalnego charakteru funkcji Ackleya. Algorytm nie posiada mechanizmu pozwalającego opuścić lokalne doliny, dlatego mimo poprawnie działającej procedury optymalizacji nie jest w stanie odnaleźć minimum globalnego.

Podsumowując, zmiana parametru α wpływa jedynie na tempo i stabilność zbieżności, ale nie eliminuje problemu utknięcia w minimach lokalnych, typowego dla funkcji Ackleya.

6 Eksperyment 4: Wpływ punktu startowego

W ostatniej części eksperymentów postanowiono zbadać, czy wybór punktu startowego x_0 ma istotny wpływ na wynik działania algorytmu Gradient Descent. Dla ustalonych parametrów:

$$\alpha = 0.01, \qquad \varepsilon = 10^{-6},$$

uruchomiono algorytm dla wielu różnych punktów startowych równomiernie rozmieszczonych w przedziale $[-4, 4]$.

Dla każdego x_0 zapisano znalezione minimum $x^\star$ oraz wartość funkcji $f(x^\star)$. Otrzymane wyniki przedstawiono na poniższym wykresie:

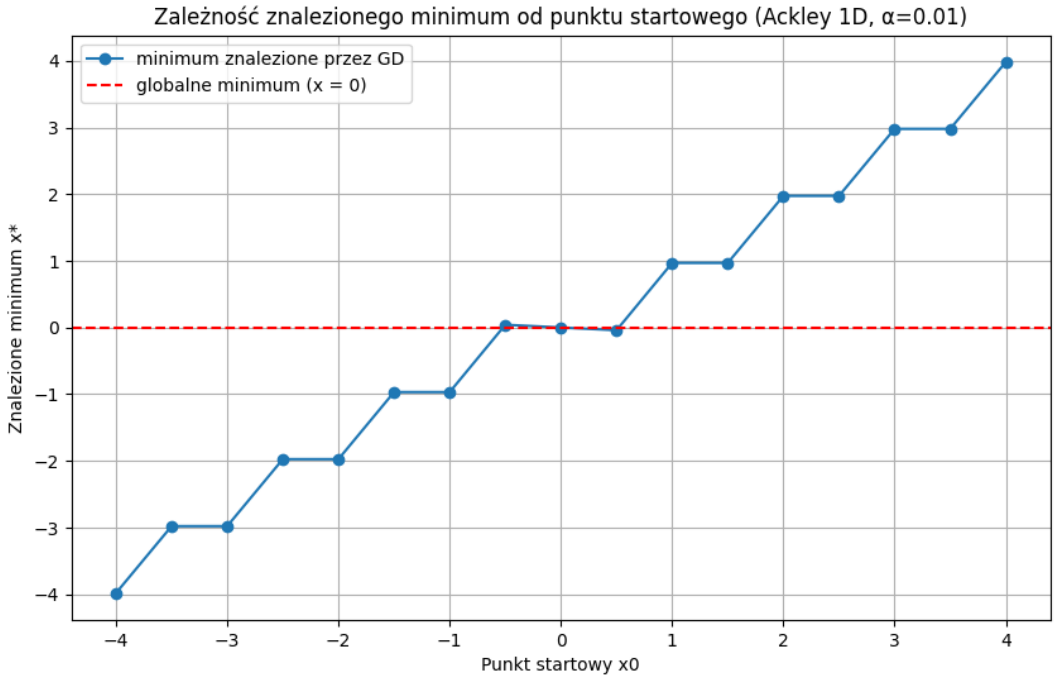

x_0	$x_{\min}$	$f(x_{\min})$	Iteracje
-4.0	-3.983068	1.099826e+01	6
-3.5	-2.979224	9.001093e+00	15
-3.0	-2.979224	9.001093e+00	6
-2.5	-1.974452	6.559645e+00	14
-2.0	-1.974452	6.559645e+00	5
-1.5	-0.968478	3.574452e+00	13
-1.0	-0.968478	3.574452e+00	5
-0.5	0.040789	2.498436e-01	1001
0.0	0.0	4.440892e-16	1
0.5	-0.040789	2.498436e-01	1001
1.0	0.968478	3.574452e+00	5
1.5	0.968478	3.574452e+00	13
2.0	1.974452	6.559645e+00	5
2.5	1.974452	6.559645e+00	14
3.0	2.979224	9.001093e+00	6
3.5	2.979224	9.001093e+00	15
4.0	3.983068	1.099826e+01	6

Tabela 3: Wpływ punktu startowego x_0 na wynik działania algorytmu

Wnioski

- Algorytm Gradient Descent nie znajduje globalnego minimum funkcji Ackleya, jedynie minima lokalne.
- W większości przypadków algorytm kończy działanie bardzo blisko punktu startowego. Oznacza to, że już po kilku iteracjach trafia na pierwsze napotkane minimum lokalne i nie jest w stanie go opuścić.
- Szczególnie interesujące są przypadki $x_0 = \pm 0.5$, dla których liczba iteracji jest znacznie większa niż w pozostałych punktach. W tych miejscach funkcja Ackleya jest niemal płaska, a gradient bardzo mały, co powoduje, że algorytm wykonuje minimalne kroki i potrzebuje wielu iteracji, aby osiągnąć warunek stopu.

7 Podsumowanie

Przeprowadzone eksperymenty pokazują, że Gradient Descent nie radzi sobie dobrze z minimalizacją funkcji Ackleya. Funkcja ta posiada wiele minimów lokalnych, przez co algorytm łatwo w nich „utkwi” i nie jest w stanie dotrzeć do minimum globalnego.

Zauważono również, że:

- wynik silnie zależy od punktu startowego - algorytm często kończy bardzo blisko miejsca, z którego rozpoczął działanie,
- parametr kroku α wpływa głównie na szybkość i stabilność zbieżności, lecz nie rozwiązuje problemu minimów lokalnych,

- dla średnich wartości α zbieżność jest najszybsza, ale nadal prowadzi do minimum lokalnego, a nie globalnego.