# Analiza działania algorytmu Gradient Descent na funkcji Ackleya

Oliwia Wójcicka

10.12.2025

## 1 Algorytm Gradient Descent

Algorytm Gradient Descent jest podstawową iteracyjną metodą służącą do znajdowania minimum funkcji różniczkowalnych. Algorytm aktualizuje punkt w kierunku przeciwnym do gradientu:

$$x_{k+1} = x_k - \alpha \nabla f(x_k),$$

gdzie $\alpha > 0$ jest krokiem nauki. Metoda ta dobrze sprawdza się dla funkcji gładkich i wypukłych, natomiast w przypadku funkcji wielomodalnych (posiadających wiele minimów lokalnych) może łatwo utknąć w lokalnych minimach, oscylować lub nie zbiegać. Warunek stopu zwykle opiera się na normie gradientu:

$$\|\nabla f(x_k)\| \leq \varepsilon.$$

co oznacza osiągnięcie punktu stacjonarnego.

## 2 Funkcja Ackleya

Zgodnie z treścią zadania analizujemy działanie algorytmu Gradient Descent na funkcji Ackleya w wersji jednowymiarowej i dwuwymiarowej, opisanych odpowiednio wzorami:

$$f(x) = -20 \exp\left(-0.2\sqrt{x^2}\right) - \exp(\cos(2\pi x)) + 20 + e.$$

$$f(x,y) = -20 \exp\left(-0.2\sqrt{\frac{x^2+y^2}{2}}\right) - \exp\left(\frac{\cos(2\pi x) + \cos(2\pi y)}{2}\right) + 20 + e.$$

W obu przypadkach funkcja posiada jedno globalne minimum zlokalizowane w punkcie:

$$(x^*, y^*) = (0,0), \qquad f(0,0) = 0.$$

natomiast liczne oscylacje powodują, że otoczenie funkcji jest pełne minimów lokalnych o różnych głębokościach. To sprawia, że Ackley stanowi wymagający test dla algorytmów optymalizacji lokalnej - takich jak Gradient Descent - i pozwala obserwować typowe problemy związane z ich stosowaniem w kontekście funkcji wielomodalnych.

### Wizualizacja

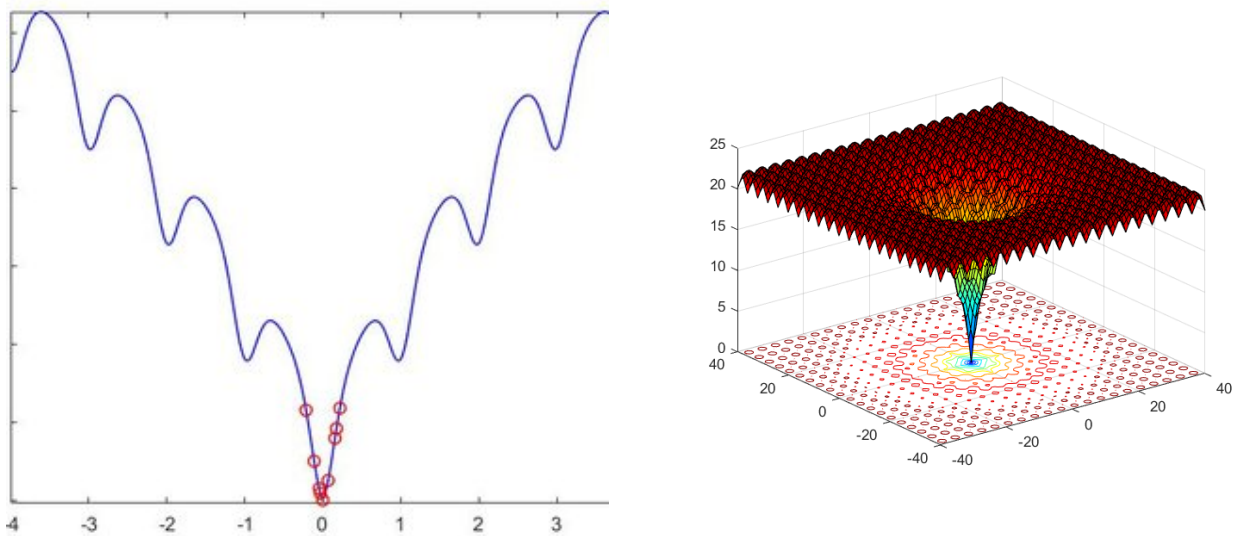


Rysunek 1: Porównanie wizualizacji funkcji Ackleya w 1 i 2 wymiarach

## 3 Eksperyment 1: Minima funkcji Ackleya

W pierwszym etapie przeprowadzono test działania algorytmu Gradient Descent dla ustalonych parametrów

$$x_0 = [2.0], \qquad \alpha = 0.01, \qquad \varepsilon = 10^{-6}$$

w przypadku funkcji jednowymiarowej oraz

$$x_0 = [1.0,\ 1.0], \qquad \alpha = 0.01, \qquad \varepsilon = 10^{-6}$$

dla wersji dwuwymiarowej.

Otrzymane minima były następujące:

$$x_{\min}^{(1D)} = 1.97445199, \qquad f\left(x_{\min}^{(1D)}\right) = 6.55964538,$$

$$(x_{\min}^{(2D)}, y_{\min}^{(2D)}) = (0.96847767,\ 0.96847767), \qquad f\left(x_{\min}^{(2D)}, y_{\min}^{(2D)}\right) = 3.574451877.$$

Żaden z otrzymanych wyników nie jest nawet bliski wartości globalnego minimum funkcji Ackleya, które wynosi

$$(x^\star, y^\star) = (0, 0), \qquad f(0, 0) = 0.$$

Co więcej, wartości funkcji w znalezionych punktach ($f > 3$) jednoznacznie potwierdzają, że nie są to minima globalne. Już na tym etapie zauważyłam również wyraźną zależność wyniku od wyboru punktu startowego, co zostanie dokładniej przeanalizowane w kolejnych eksperymentach.

# 4 Eksperyment 2: Wpływ rozmiaru kroku $\alpha$ na działanie algorytmu

Kolejnym etapem było zbadanie, w jaki sposób wybór parametru kroku $\alpha$ wpływa na działanie algorytmu. W tym celu uruchomiono algorytm dla wielu różnych wartości $\alpha$, przy stałych parametrach:

$$x_0 = 2.0 \quad (1\text{D}), \qquad (x_0, y_0) = (2.0, 2.0) \quad (2\text{D}), \qquad \varepsilon = 10^{-6}.$$

Dla każdej wartości kroku zarejestrowano przebieg funkcji $f(x_k)$ w kolejnych iteracjach oraz zachowanie algorytmu pod względem zbieżności lub niestabilności.

# 5 Eksperyment 3: Wpływ rozmiaru kroku $\alpha$ na działanie algorytmu

W kolejnym etapie przeprowadzono analizę wpływu parametru kroku $\alpha$ na zachowanie algorytmu gradientu prostego. W tym celu uruchomiono algorytm dla wielu różnych wartości $\alpha$, zarówno dla funkcji Ackleya w wymiarze 1, jak i 2, przy stałych parametrach:

$$x_0 = 2.0 \quad (1\text{D}), \qquad (x_0, y_0) = (2.0, 2.0) \quad (2\text{D}), \qquad \varepsilon = 10^{-6}.$$

Dla każdej wartości kroku zarejestrowano przebieg funkcji $f(x_k)$ w kolejnych iteracjach oraz zachowanie algorytmu pod względem zbieżności lub niestabilności.

## 5.1 Wykresy

Poniższe wykresy przedstawiają zachowanie algorytmu dla różnych wartości parametru $\alpha$. Każdy wykres odpowiada innej wartości kroku, co umożliwia porównanie dynamiki zbieżności.

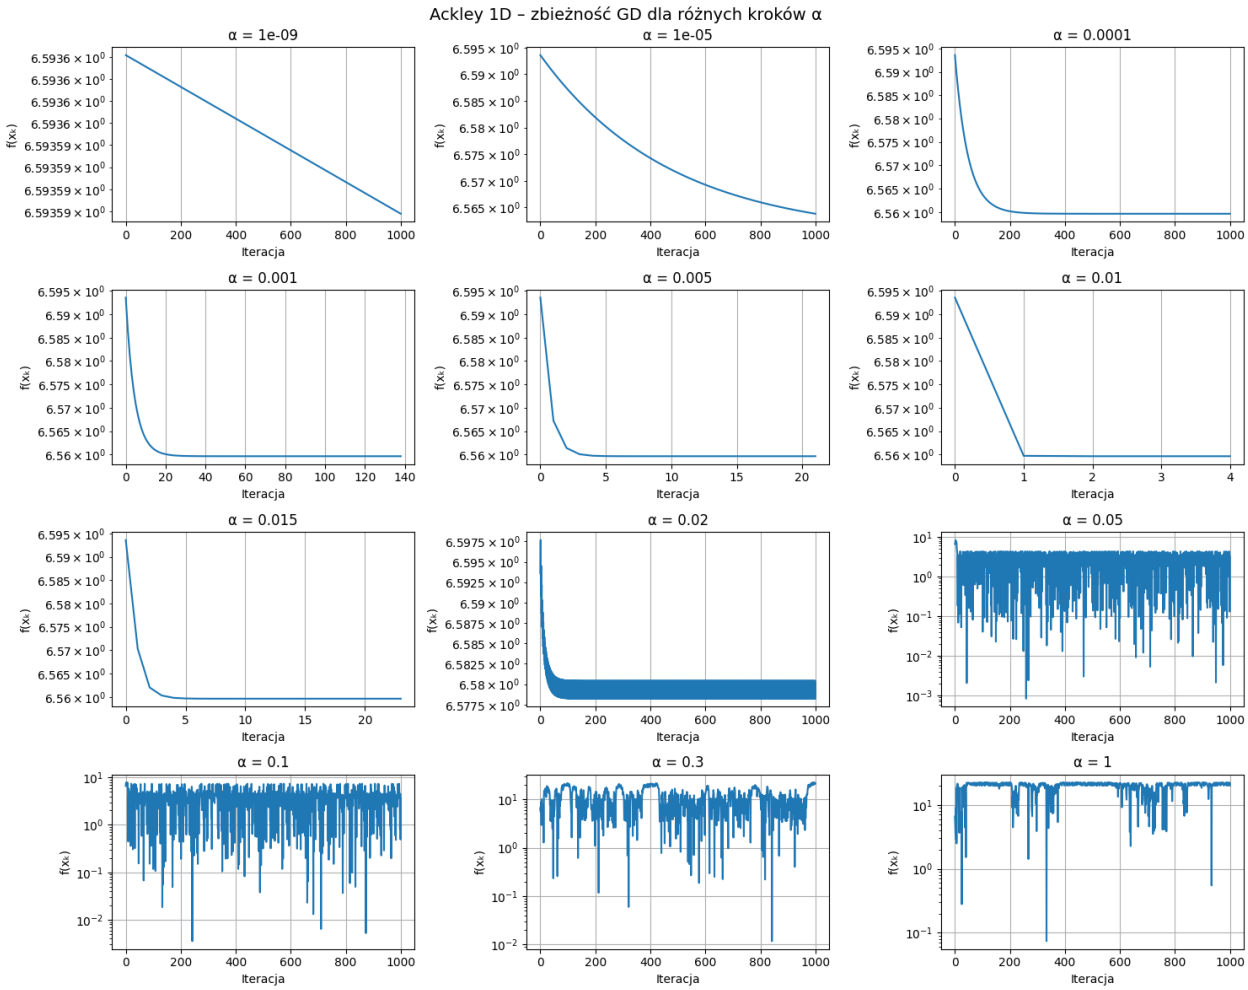


Rysunek 2: zbieżność Gradient Descent na funkcji Ackleya 1D kroku

## Wnioski na podstawie wykresów

Analiza wykresów dla różnych wartości kroku $\alpha$ pozwala wyciągnąć kilka obserwacji dotyczących zachowania algorytmu Gradient Descent:

- **Bardzo małe wartości** $\alpha$ powodują bardzo wolne działanie algorytmu. Zmiany wartości funkcji w kolejnych iteracjach są minimalne, a algorytm wykonuje dużą liczbę kroków, praktycznie stojąc w miejscu.
- **Średnie wartości kroku** (w okolicach $\alpha$ około $10^{-3}$–$10^{-2}$) prowadzą do najbardziej stabilnej i najszybszej zbieżności. W tych przypadkach wykresy pokazują szybkie obniżanie wartości funkcji, a liczba iteracji jest najmniejsza.
- **Duże wartości** $\alpha$ powodują utratę stabilności metody. Wartości $f(x_k)$ zaczynają oscylować, niekiedy bardzo gwałtownie, a algorytm nie jest w stanie ustabilizować się w żadnym punkcie.

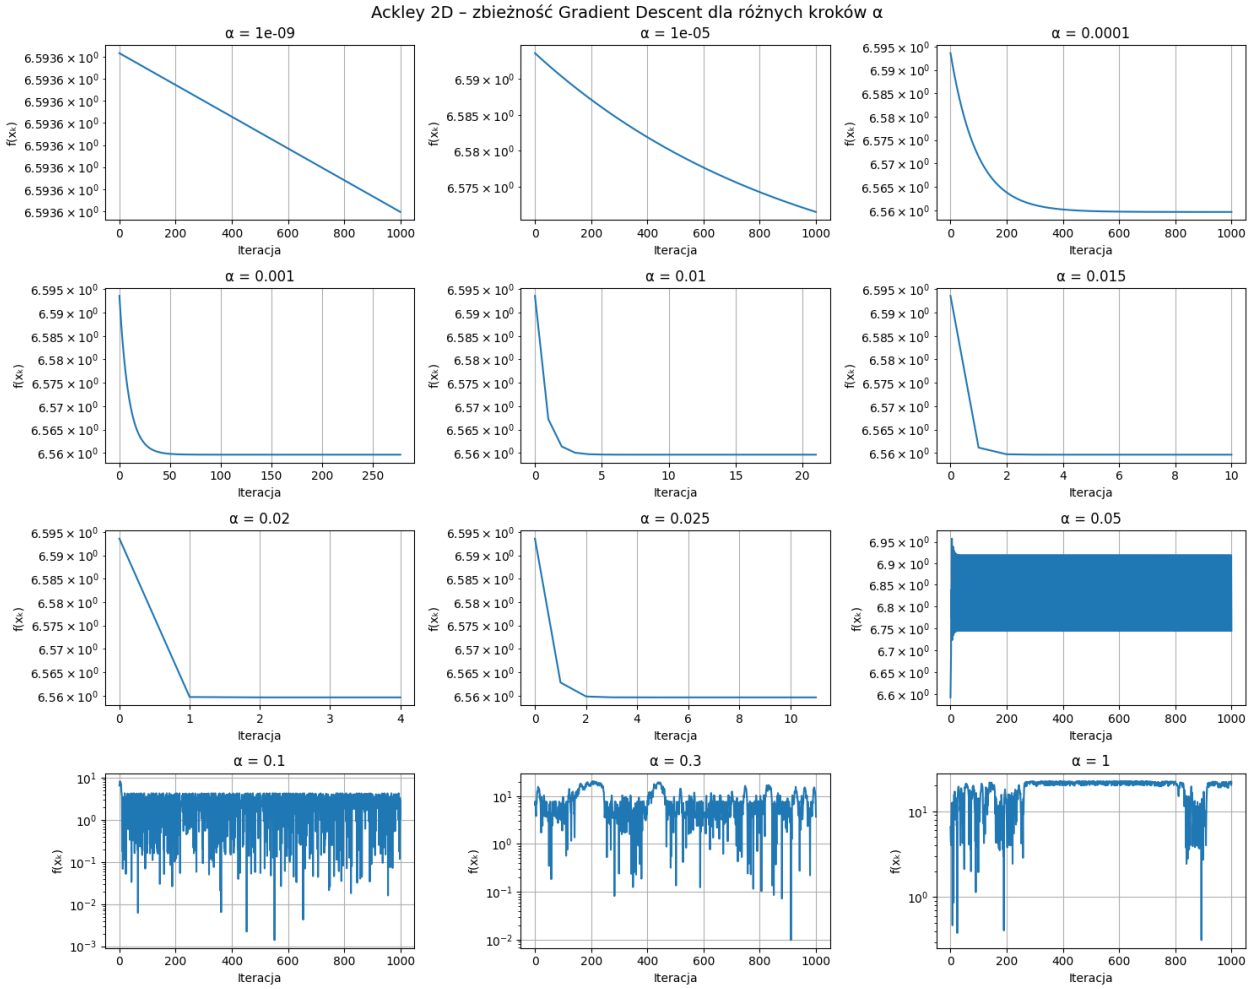


Rysunek 3: zbieżność Gradient Descent na funkcji Ackleya 2D

Podsumowując, wybór parametru kroku ma kluczowe znaczenie dla stabilności i szybkości algorytmu. Dobrze dobrane średnie wartości $\alpha$ pozwalają osiągnąć szybką zbieżność, natomiast zbyt małe lub zbyt duże kroki prowadzą odpowiednio do bardzo wolnego działania lub do niestabilności.

## 5.2 Wyniki numeryczne

## Wnioski na podstawie wyników z tabel

Z tabel wynika, że średnie wartości kroku $\alpha$ (około $10^{-3}$–$10^{-2}$) powodują najszybszą zbieżność algorytmu - liczba iteracji jest wtedy znacznie mniejsza niż dla bardzo małych lub dużych kroków.

Jednak mimo różnic w szybkości zbieżności wszystkie znalezione punkty $x_{\min}$ oraz $f(x_{\min})$ (zarówno w 1D, jak i w 2D) są wyraźnie oddalone od faktycznego minimum globalnego funkcji Ackleya. Oznacza to, że Gradient Descent regularnie zatrzymuje się w minimach lokalnych, co wynika z silnie multimodalnego charakteru funkcji Ackleya. Algorytm nie posiada mecha-

| $\alpha$ | Iteracje | $x_{\min}$ | $f(x_{\min})$ |
|---|---|---|---|
| $10^{-9}$ | 1001 | 1.999997 | 6.593592 |
| $10^{-5}$ | 1001 | 1.983483 | 6.563825 |
| $10^{-4}$ | 1001 | 1.974453 | 6.559645 |
| $10^{-3}$ | 139 | 1.974452 | 6.559645 |
| $5 \cdot 10^{-3}$ | 22 | 1.974452 | 6.559645 |
| $10^{-2}$ | 5 | 1.974452 | 6.559645 |
| $1.5 \cdot 10^{-2}$ | 24 | 1.974452 | 6.559645 |
| $2 \cdot 10^{-2}$ | 1001 | 1.993397 | 6.578220 |
| $5 \cdot 10^{-2}$ | 1001 | -0.304790 | 3.187469 |
| $10^{-1}$ | 1001 | -0.966769 | 3.574595 |
| $3 \cdot 10^{-1}$ | 1001 | -22.824044 | 20.943882 |
| 1 | 1001 | 97.053690 | 20.148973 |

Tabela 1: Wyniki minimalizacji funkcji Ackleya 1D

| $\alpha$ | Iteracje | $(x_{\min}, y_{\min})$ | $f(x_{\min}, y_{\min})$ |
|---|---|---|---|
| $10^{-9}$ | 1001 | (1.999998, 1.999998) | 6.593595 |
| $10^{-5}$ | 1001 | (1.989606, 1.989606) | 6.571489 |
| $10^{-4}$ | 1001 | (1.974604, 1.974604) | 6.559647 |
| $10^{-3}$ | 278 | (1.974452, 1.974452) | 6.559645 |
| $10^{-2}$ | 22 | (1.974452, 1.974452) | 6.559645 |
| $1.5 \cdot 10^{-2}$ | 11 | (1.974452, 1.974452) | 6.559645 |
| $2 \cdot 10^{-2}$ | 5 | (1.974452, 1.974452) | 6.559645 |
| $2.5 \cdot 10^{-2}$ | 12 | (1.974452, 1.974452) | 6.559645 |
| $5 \cdot 10^{-2}$ | 1001 | (2.033833, 2.033833) | 6.744515 |
| $10^{-1}$ | 1001 | (-0.116062, -0.116062) | 1.069301 |
| $3 \cdot 10^{-1}$ | 1001 | (0.381496, 0.381496) | 3.708173 |
| 1 | 1001 | (-33.749212, -33.749212) | 21.699794 |

Tabela 2: Wyniki minimalizacji funkcji Ackleya 2D

nizmu pozwalającego opuścić lokalne doliny, dlatego mimo poprawnie działającej procedury optymalizacji nie jest w stanie odnaleźć minimum globalnego.

Podsumowując, zmiana parametru $\alpha$ wpływa jedynie na tempo i stabilność zbieżności, ale nie eliminuje problemu utknięcia w minimach lokalnych, typowego dla funkcji Ackleya.

# 6 Eksperyment 4: Wpływ punktu startowego

W ostatniej części eksperymentów postanowiono zbadać, czy wybór punktu startowego $x_0$ ma istotny wpływ na wynik działania algorytmu Gradient Descent. Dla ustalonych parametrów:

$$\alpha = 0.01, \qquad \varepsilon = 10^{-6},$$

uruchomiono algorytm dla wielu różnych punktów startowych równomiernie rozmieszczonych w przedziale $[-4, 4]$.

Dla każdego $x_0$ zapisano znalezione minimum $x^\star$ oraz wartość funkcji $f(x^\star)$. Otrzymane wyniki przedstawiono na poniższym wykresie:

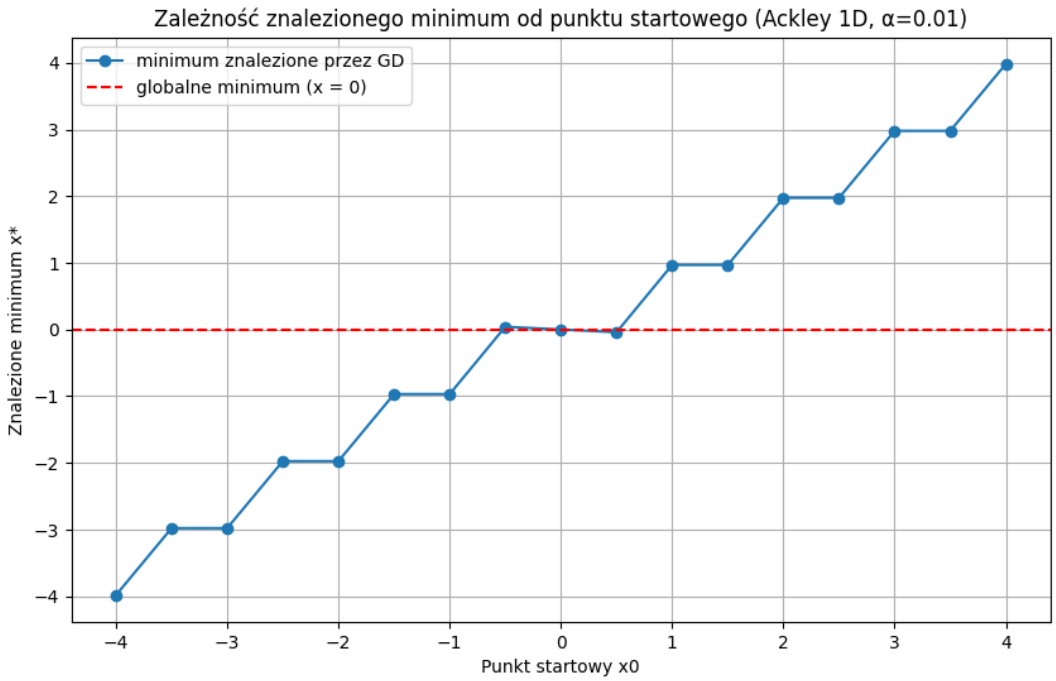


| $x_0$ | $x_{\min}$ | $f(x_{\min})$ | Iteracje |
|---|---|---|---|
| -4.0 | -3.983068 | 1.099826e+01 | 6 |
| -3.5 | -2.979224 | 9.001093e+00 | 15 |
| -3.0 | -2.979224 | 9.001093e+00 | 6 |
| -2.5 | -1.974452 | 6.559645e+00 | 14 |
| -2.0 | -1.974452 | 6.559645e+00 | 5 |
| -1.5 | -0.968478 | 3.574452e+00 | 13 |
| -1.0 | -0.968478 | 3.574452e+00 | 5 |
| -0.5 | 0.040789 | 2.498436e-01 | 1001 |
| 0.0 | 0.0 | 4.440892e-16 | 1 |
| 0.5 | -0.040789 | 2.498436e-01 | 1001 |
| 1.0 | 0.968478 | 3.574452e+00 | 5 |
| 1.5 | 0.968478 | 3.574452e+00 | 13 |
| 2.0 | 1.974452 | 6.559645e+00 | 5 |
| 2.5 | 1.974452 | 6.559645e+00 | 14 |
| 3.0 | 2.979224 | 9.001093e+00 | 6 |
| 3.5 | 2.979224 | 9.001093e+00 | 15 |
| 4.0 | 3.983068 | 1.099826e+01 | 6 |

Tabela 3: Wpływ punktu startowego $x_0$ na wynik działania algorytmu

### Wnioski

- Algorytm Gradient Descent nie znajduje globalnego minimum funkcji Ackleya, jedynie minima lokalne.
- W większości przypadków algorytm kończy działanie bardzo blisko punktu startowego. Oznacza to, że już po kilku iteracjach trafia na pierwsze napotkane minimum lokalne i nie jest w stanie go opuścić.
- Szczególnie interesujące są przypadki $x_0 = \pm 0.5$, dla których liczba iteracji jest znacznie większa niż w pozostałych punktach. W tych miejscach funkcja Ackleya jest niemal płaska, a gradient bardzo mały, co powoduje, że algorytm wykonuje minimalne kroki i potrzebuje wielu iteracji, aby osiągnąć warunek stopu.

## 7 Podsumowanie

Przeprowadzone eksperymenty pokazują, że Gradient Descent nie radzi sobie dobrze z minimalizacją funkcji Ackleya. Funkcja ta posiada wiele minimów lokalnych, przez co algorytm łatwo w nich „utkwi” i nie jest w stanie dotrzeć do minimum globalnego.

Zauważono również, że:

- wynik silnie zależy od punktu startowego - algorytm często kończy bardzo blisko miejsca, z którego rozpoczął działanie,
- parametr kroku $\alpha$ wpływa głównie na szybkość i stabilność zbieżności, lecz nie rozwiązuje problemu minimów lokalnych,
- dla średnich wartości $\alpha$ zbieżność jest najszybsza, ale nadal prowadzi do minimum lokalnego, a nie globalnego.